

Universidad Nacional de Colombia

Trabajo 2

Departamento de de Ciencias de la Computación y de la Decisión
Facultad de Minas

Integrantes:

Juan Manuel Diaz Larrea
Kevin Hair González Duarte
Manuel Gutierrez Tangarife
Mariana Ruiz Zamora
Maria Fernanda Valencia Jimenez

Medellín, Colombia
Semestre 2026 - 02
30 de octubre de 2026

Índice

1. Repositorio GitHub **6**

2. Video promocional **6**

3. Video de contribución individual **6**

4. Punto 1 **6**

4.1. Fundamentación matemática . . . 6
4.1.1. Neurona artificial . . . 6
4.1.2. Regresión logística: el modelo y la razón de odds . . . 6
4.1.3. Perceptrón multicapa . . . 7
4.1.4. Funciones de activación . . . 8
4.1.5. Funciones de pérdida por máxima verosimilitud . . . 8
4.1.6. Retropropagación . . . 9
4.1.7. Optimizador de la red: Adam . . . 10
4.1.8. Optimizadores de la regresión logística . . . 10
4.1.9. Inferencia sobre los coeficientes de la regresión logística . . . 11
4.1.10. Regularización . . . 12
4.1.11. Métricas de evaluación . . . 13
4.1.12. Derivación de la scorecard . . . 15
4.2. Caso de uso . . . 16
4.3. Preprocesamiento de datos . . . 16
4.3.1. Población y variables descartadas . . . 20
4.3.2. Recodificación y construcción de variables . . . 20
4.3.3. Tratamiento de valores ausentes . . . 21
4.3.4. Valores extremos . . . 22
4.3.5. Transformaciones . . . 22
4.3.6. Variables categóricas . . . 23
4.3.7. Estandarización . . . 23
4.3.8. Verificaciones . . . 23
4.4. Análisis descriptivo . . . 23
4.4.1. Asociación entre las variables y el incumplimiento . . . 23
4.4.2. Variables numéricas . . . 24
4.4.3. Variables discretas . . . 26
4.4.4. Relación conjunta entre la carga de deuda y la utilización del crédito rotativo . . . 27
4.5. Modelo de referencia . . . 27
4.5.1. Especificación y selección del hiperparámetro . . . 27
4.5.2. Métricas de evaluación . . . 28
4.5.3. Resultados en entrenamiento, validación y prueba . . . 28
4.5.4. Recalibración del intercepto . . . 30
4.5.5. Síntesis . . . 30
4.6. Red Neuronal . . . 31
4.6.1. Cómo está hecha . . . 31
4.6.2. Hiperparámetros . . . 32
4.6.3. Método de búsqueda: búsqueda aleatoria . . . 32
4.6.4. Por qué una búsqueda aleatoria y no una grilla . . . 33
4.6.5. Por qué no emplear métodos más sofisticados (búsqueda bayesiana) . . . 33
4.6.6. Por qué evaluar con un semestre posterior . . . 33
4.6.7. Hallazgos principales . . . 33

4.6.8. Resultado: La red no le gana a la logística . . . 33
4.7. Evaluación . . . 34
4.7.1. Partición de los datos . . . 34
4.7.2. Por qué se analizaron únicamente créditos a 36 meses . . . 34
4.7.3. Por qué se excluyó el periodo 2013–2015 . . . 35
4.7.4. Discriminación: ¿pone a los malos por encima de los buenos? . . . 35
4.7.5. Calibración . . . 37
4.7.6. Conclusión . . . 38
4.8. Scorecard . . . 39
4.8.1. De probabilidad a puntaje . . . 39
4.8.2. Cómo salen los puntos del modelo . . . 40
4.8.3. Ejemplo . . . 41
4.9. Variables de riesgo . . . 42
4.9.1. Qué variables pesan más . . . 43
4.9.2. Qúe hace más riesgosa a una persona . . . 43
4.9.3. Cómo cambia el riesgo con cada variable . . . 44
4.9.4. Nota . . . 44
4.10. Verificación de las pruebas de hipótesis . . . 44
4.11. Discusión y regla de comparación justa . . . 46
4.11.1. ¿Qué aportó la red frente a la logística? . . . 46
4.11.2. variabilidad entre semillas . . . 46
4.11.3. Costo computacional . . . 46
4.11.4. Interpratibilidad . . . 47
4.11.5. Resultado Final . . . 47
4.11.6. Aprendizajes . . . 47

5. Punto 2 **47**
5.1. Fundamentación metodológica del punto 2 . . . 47
5.1.1. Problema de estimación . . . 47
5.2. Definición de la variable objetivo . . . 48
5.2.1. Población de análisis . . . 48
5.2.2. Variables predictoras y fuga de información . . . 48
5.2.3. Preprocesamiento y particiones . . . 48
5.2.4. Modelo de referencia: regresión lineal . . . 49
5.2.5. Variables indicadoras . . . 49
5.2.6. Neurona artificial y perceptrón multicapa . . . 49
5.2.7. Funciones de activación . . . 50
5.2.8. Función de pérdida . . . 50
5.3. Regularización . . . 51
5.3.1. Retropropagación . . . 51
5.4. Optimizador Adam . . . 51
5.4.1. Evaluación . . . 52
5.4.2. Experimentos y variabilidad . . . 52
5.4.3. Pérdida esperada y exposición . . . 52
5.4.4. Prompts representativos del punto 2 . . . 53
5.5. Resultados empíricos y comparación justa (Regresión OLS vs. Red MLP) . . . 53
5.5.1. Modelo de referencia: regresión lineal por mínimos cuadrados (OLS) . . . 53
5.5.2. Presupuesto de búsqueda de hiperparámetros de la red neuronal . . . 56
5.5.3. Evaluación sobre 30 semillas independientes y regla de comparación justa 56
5.5.4. Comparación de distribuciones y compresión de la varianza predicha . . . 57
5.6. Estimación de la pérdida esperada de cartera ($E[L] = PD \cdot LGD \cdot EAD$) . . . 58

5.6.1. Segmentación por calificación crediticia y concentración de riesgo (Curva de Lorenz) . . . 59
5.7. Discusión global y aprendizajes del proceso de modelamiento . . . 60
5.7.1. ¿Qué aportó la red neuronal frente al modelo de referencia? . . . 60
5.7.2. Listado de aprendizajes metodológicos sobre el problema . . . 60

6. Uso de IA **61**
6.1. Punto 1. Parte de Manuel . . . 61

7. Cacería de alucinaciones **63**
7.1. Primer punto . . . 63
7.1.1. Hallazgo 3: una partición con créditos que aún no habían terminado . . . 64
7.1.2. . . . 64
7.2. Segundo punto . . . 64
7.2.1. Prompt utilizado . . . 64
7.2.2. Respuesta relevante de la IA . . . 64
7.2.3. Cómo se sospechó que había un error . . . 64
7.2.4. Evidencia del problema . . . 65
7.2.5. Corrección . . . 65
7.3. Punto 2 . . . 65

Índice de figuras

1. Matriz de correlaciones de Spearman entre las variables numéricas . . . 24
2. Distribución del logaritmo del ingreso anual según la condición de incumplimiento . . . 25
3. Distribución de la relación deuda-ingreso según la condición de incumplimiento 25
4. Tasa de malos según el número de consultas de crédito en los últimos seis meses 26
5. Tasa de malos según el número de moras en los últimos dos años . . . 26
6. Tasa de malos por nivel de endeudamiento y utilización del crédito rotativo . . . 27
7. Desempeño de la regresión logística L2 ($C = 0{,}01$) en el conjunto de prueba (jul–dic 2012): curva ROC (izquierda), curva de calibración por deciles de la probabilidad estimada con intervalos de confianza del 95 %(centro) y distribución de las probabilidades estimadas (derecha). . . . 30
8. Curvas ROC de la red neuronal y la regresión logística en prueba . . . 36
9. Distribución acumulada del puntaje según la condición de incumplimiento en prueba . . . 37
10. Curva de calibración de la regresión logística en prueba . . . 38
11. De probabilidad a puntaje . . . 40
12. Comportamiento de las variables para el cliente de ejemplo . . . 41
13. Distribución de puntajes para créditos buenos y malos . . . 42
14. Comparación de cambios del AUC al desordenar cada variable . . . 43
15. Dependencia parcial de las variables más importantes y el dti . . . 44
16. Distribución del error MAE y RMSE en prueba a lo largo de las 30 semillas frente a la referencia lineal . . . 57
17. Comparación de distribuciones de LGD en prueba: densidad y funciones acumuladas (CDF) . . . 58
18. Análisis de pérdida esperada: tasa de riesgo por grado crediticio y curva de concentración de Lorenz . . . 59
19. Dispersión de riesgo: probabilidad de incumplimiento vs. severidad de pérdida . 60

Índice de cuadros

1. Comparación de modelos . . . 7
2. Parámetros de los modelos . . . 10
3. Porcentaje de valores nulos por año de originación . . . 16
4. Presencia del historial de moras recientes . . . 17
5. Moras recientes según meses desde la última mora . . . 17
6. Porcentaje de valores nulos y ceros por año de originación . . . 18
7. Presencia de registros públicos según meses desde el último registro . . . 18
8. Créditos con valor en meses desde el último registro y cero registros públicos, por año . . . 18
9. Estadísticos de endeudamiento y utilización de crédito por partición . . . 19
10. Tratamiento de cada variable y tipo de operación . . . 20
11. Desempeño de la regresión logística L2 ($C = 0{,}01$) en los conjuntos de entrenamiento, validación y prueba. . . . 29
12. Conjuntos de datos y sus usos . . . 31
13. Ajustes y evaluación del modelo . . . 32
14. Medidas en prueba . . . 34
15. Conjuntos de datos, tasa de malos y sus usos . . . 34
16. Medidas de evaluación, preguntas y escalas . . . 35
17. Comparación del rendimiento de los modelos . . . 37
18. Parámetros de escalamiento del puntaje . . . 39
19. Puntaje y lectura por variable . . . 41
20. Comparación de métricas entre modelos . . . 46
21. AUC en prueba con 30 semillas . . . 46
22. Comparativa de complejidad y tiempos de cómputo . . . 47
23. Comparación de interpretabilidad entre regresión logística y red neuronal . . . 47
24. Prompts representativos del uso de inteligencia artificial en el desarrollo del punto 2 (parte 1 de 2) . . . 54
25. Prompts representativos del uso de inteligencia artificial en el desarrollo del punto 2 (parte 2 de 2) . . . 55
26. Desempeño y complejidad del modelo de referencia lineal (OLS) en el conjunto de prueba . . . 56
27. Presupuesto de búsqueda de hiperparámetros para la red de LGD sobre el conjunto de validación . . . 56
28. Comparación justa: Regresión OLS vs. Red Neuronal MLP a través de 30 semillas independientes . . . 57
29. Estadísticos descriptivos y cuantiles de LGD observada vs. predicha en prueba . . . 58
30. Métricas consolidadas de pérdida esperada a nivel de portafolio crediticio . . . 59
31. Atención a observaciones y requerimientos del proyecto . . . 62

1. Repositorio GitHub

https://github.com/MgtDevNet/T02_REDES_NEURONALES_

2. Video promocional

https://www.youtube.com/watch?v=cy8w_VjKIy0 **Sugerencia:** subir calidad del video, por defecto es muy baja.

3. Video de contribución individual

https://youtu.be/1IBOLA7lWLg

4. Punto 1

4.1. Fundamentación matemática

Notación. Se dispone de n créditos. El crédito i tiene un vector de variables $\mathbf{x}_i \in \mathbb{R}^d$ (con $d = 30$ tras el preprocesamiento) y un resultado y_i. La matriz $X \in \mathbb{R}^{n\times d}$ tiene por filas a $\mathbf{x}_i^\top$ y $\mathbf{y}$ es el vector de resultados. El símbolo θ agrupa todos los parámetros del modelo, $J(\theta)$ es la pérdida promedio sobre los n créditos y σ es la sigmoide. En la probabilidad de incumplimiento (PD), $y_i = 1$ indica un crédito malo y $p_i = \hat{y}_i$ es la probabilidad estimada.

4.1.1. Neurona artificial

Una neurona combina sus entradas de forma lineal y aplica una función no lineal. Recibe $\mathbf{x} \in \mathbb{R}^d$, la pondera con pesos $\mathbf{w}$ y le suma un sesgo b:

$$z = \mathbf{w}^\top \mathbf{x} + b, \qquad \hat{y} = \phi(z)$$

- z es la preactivación: el puntaje lineal.
- ϕ es la función de activación.
- $\hat{y}$ es la salida de la neurona.

Si ϕ es la sigmoide, una sola neurona es exactamente una regresión logística (sección 4.1.2). McCulloch y Pitts 1943; Rosenblatt 1958

4.1.2. Regresión logística: el modelo y la razón de odds

La regresión logística es el modelo de referencia de la PD. Supone que $y_i \mid \mathbf{x}_i \sim \text{Bernoulli}(p_i)$ con

$$p_i = P(y_i = 1 \mid \mathbf{x}_i) = \sigma(z_i), \qquad z_i = \mathbf{w}^\top \mathbf{x}_i + b, \qquad \sigma(z) = \frac{1}{1+e^{-z}}.$$

La sigmoide es la elección natural por tres razones. Primero, un puntaje lineal z puede tomar cualquier valor real, mientras que una probabilidad debe estar en $(0,1)$: como $e^{-z} > 0$, el denominador es mayor que 1 y por eso $0 < \sigma(z) < 1$ para todo z, con $\sigma(z) \to 1$ cuando $z \to +\infty$ y $\sigma(z) \to 0$ cuando $z \to -\infty$. Segundo, $\sigma(0) = 1/2$ y $\sigma(-z) = 1 - \sigma(z)$: invertir el signo del puntaje intercambia las dos clases. Tercero, σ es estrictamente creciente, así que ordenar los créditos por p_i equivale a ordenarlos por z_i.

Las *odds* (malos : buenos) y su logaritmo se obtienen despejando:

$$\frac{p}{1-p} = \frac{1/(1+e^{-z})}{e^{-z}/(1+e^{-z})} = e^{z} \qquad \Longleftrightarrow \qquad \ln \frac{p}{1-p} = b + \sum_{j=1}^{d} w_j x_j.$$

Es decir, el modelo es lineal en el logaritmo de las odds (*logit*). Si x_j aumenta Δ unidades y las demás variables no cambian, el logit aumenta $w_j\Delta$ y las odds se multiplican por $e^{w_j\Delta}$. Con $\Delta = 1$ ese factor es la *razón de odds* (OR) de la variable:

$$\mathrm{OR}_j = e^{w_j}, \qquad \mathrm{OR}_j > 1 \iff w_j > 0 \iff \text{mayor riesgo.}$$

En las variables estandarizadas, $\Delta = 1$ equivale a una desviación estándar; en las variables ficticias, a pasar de la categoría de referencia a la categoría en cuestión. La interpretación es condicional (con las demás variables fijas) y multiplicativa sobre las odds, no aditiva sobre la probabilidad: $\partial p/\partial x_j = w_j\, p(1-p)$, de modo que el cambio en probabilidad depende del nivel de partida. Nótese que en esta sección las odds son malos : buenos, mientras que la scorecard (sección 4.1.12) usa su inversa, buenos : malos.

El logit es el enlace canónico de la distribución Bernoulli, lo que explica la forma sencilla de la pérdida y su gradiente (sección 4.1.5). El modelo supone observaciones independientes dadas las variables, y un efecto lineal y aditivo de cada variable sobre el logit, sin interacciones salvo que se incluyan. Esos supuestos son justamente los que el perceptrón multicapa relaja.

Hosmer, Lemeshow y Sturdivant 2013; McCullagh y Nelder 1989

4.1.3. Perceptrón multicapa

Un MLP apila capas de neuronas: la salida de cada capa es la entrada de la siguiente. Con X ($n \times d$) y L capas con pesos:

$$A^{[0]} = X, \qquad Z^{[l]} = A^{[l-1]}W^{[l]} + \mathbf{b}^{[l]}, \qquad A^{[l]} = g_l\left(Z^{[l]}\right), \quad l = 1, \ldots, L$$

La salida es $\hat{\mathbf{y}} = A^{[L]}$, una sola neurona. La regresión logística de referencia es el caso $L = 1$ con $g_1 = \sigma$.

Tabla 1
Comparación de modelos

Modelo	Capas ocultas	Activación oculta	Salida
PD (red)	64, 32	ReLU	sigmoide (probabilidad de ser malo)
PD (logística de referencia)	ninguna	—	sigmoide
LGD (red)	32, 16	ReLU	sigmoide (LGD en $(0,1)$)

Nota. PD = probabilidad de incumplimiento; LGD = pérdida dado el incumplimiento.

Inicialización. Los pesos de las capas ReLU usan He, con $\mathrm{Var}(W) = 2/n_{\text{ent}}$. El resto usa Glorot, con $\mathrm{Var}(W) = 2/(n_{\text{ent}} + n_{\text{sal}})$. Los sesgos empiezan en 0. Así la señal no explota ni se apaga al atravesar las capas.

Rumelhart, Hinton y Williams 1986, Goodfellow, Bengio y Courville 2016, cap. 6; inicialización: Glorot y Bengio 2010; He et al. 2015

4.1.4. Funciones de activación

En los modelos finales se usan ReLU en las capas ocultas y sigmoide en la salida. Tanh e identidad están implementadas y se exploraron en la búsqueda de hiperparámetros. Cada activación necesita su derivada para la retropropagación.

ReLU (capas ocultas): deja pasar lo positivo y anula lo negativo. Es barata y no se satura para $z > 0$.

$$\phi(z) = \text{máx}(0, z), \qquad \phi'(z) = \begin{cases} 1 & z > 0 \\ 0 & z \leq 0 \end{cases}$$

Sigmoide (salida de PD y LGD, y única activación de la regresión logística): lleva cualquier número real a $(0, 1)$, así que la salida se lee como una probabilidad o una fracción.

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \qquad \sigma'(z) = \sigma(z)\,\big(1 - \sigma(z)\big)$$

La derivada se obtiene con la regla de la cadena: $\sigma'(z) = e^{-z}(1 + e^{-z})^{-2} = \sigma(z) \cdot \frac{e^{-z}}{1+e^{-z}} = \sigma(z)\big(1 - \sigma(z)\big)$.

tanh (alternativa en la búsqueda): sigue la misma idea con valores en $(-1, 1)$ y centrada en 0.

$$\tanh(z) = \frac{e^{z} - e^{-z}}{e^{z} + e^{-z}}, \qquad \tanh'(z) = 1 - \tanh^2(z)$$

Identidad (salida opcional para la LGD): $\phi(z) = z$ y $\phi'(z) = 1$. Si se combina con ECM y no hay capas ocultas, el modelo es una regresión lineal.

Nair e Hinton 2010; Glorot y Bengio 2010, Goodfellow, Bengio y Courville 2016, secs. 6.2.2 y 6.3

4.1.5. Funciones de pérdida por máxima verosimilitud

Se supone una distribución para y dado $\mathbf{x}$, cuyo parámetro es la salida del modelo. Luego se maximiza la verosimilitud, que equivale a minimizar el promedio de $-$ log-verosimilitud.

PD: entropía cruzada binaria (modelo Bernoulli). Aquí $y \in \{0, 1\}$, donde 1 es un crédito malo. Se supone $y \mid \mathbf{x} \sim \text{Bernoulli}(p)$, con $p = \sigma(z)$ la salida del modelo. Con créditos independientes, la verosimilitud es el producto de las probabilidades individuales, y su logaritmo es una suma:

$$P(y_i \mid \mathbf{x}_i) = p_i^{y_i}(1 - p_i)^{1 - y_i} \;\Rightarrow\; \ell(\theta) = \sum_{i=1}^{n} \big[\, y_i \log p_i + (1 - y_i) \log(1 - p_i) \big]$$

Cada término tiene un papel: si el crédito fue malo ($y_i = 1$) solo cuenta $\log p_i$, y si fue bueno ($y_i = 0$) solo cuenta $\log(1 - p_i)$. Como $\ell \leq 0$, se minimiza $-\ell$, y el factor $1/n$ hace que la pérdida no dependa del tamaño de la muestra:

$$J(\theta) = -\frac{1}{n}\,\ell(\theta) = -\frac{1}{n} \sum_{i=1}^{n} \big[\, y_i \log p_i + (1 - y_i) \log(1 - p_i) \big]$$

Para que el cálculo sea estable se reescribe en función de z. Así nunca aparece $\log(0)$:

$$J = \frac{1}{n} \sum_{i=1}^{n} \big[\log(1 + e^{z_i}) - y_i z_i \big]$$

PD: gradiente, hessiana y convexidad en la regresión logística. En la regresión logística se agrupan el sesgo y los pesos en $\theta = (b, \mathbf{w}^\top)^\top \in \mathbb{R}^{d+1}$ y se extienden las variables con un 1: $\tilde{\mathbf{x}}_i = (1, \mathbf{x}_i^\top)^\top$ y $\tilde{X} = [\mathbf{1}\ X] \in \mathbb{R}^{n\times(d+1)}$, de modo que $z_i = \tilde{\mathbf{x}}_i^\top \theta$. Como $\frac{\partial}{\partial z}\log(1+e^z) = \sigma(z)$, cada término de la forma estable aporta $\frac{\partial J}{\partial z_i} = \frac{1}{n}(p_i - y_i)$, y por la regla de la cadena

$$\nabla J(\theta) = \frac{1}{n}\sum_{i=1}^{n}(p_i - y_i)\,\tilde{\mathbf{x}}_i = \frac{1}{n}\,\tilde{X}^\top(\mathbf{p} - \mathbf{y}).$$

El gradiente es el error (predicho menos observado) ponderado por las variables. Derivando de nuevo y usando $\sigma'(z) = p(1-p)$, la matriz hessiana es

$$H(\theta) = \frac{1}{n}\sum_{i=1}^{n} p_i(1-p_i)\,\tilde{\mathbf{x}}_i\tilde{\mathbf{x}}_i^\top = \frac{1}{n}\,\tilde{X}^\top W\tilde{X}, \qquad W = \operatorname{diag}\big(p_i(1-p_i)\big).$$

Para cualquier vector $\mathbf{v}$ se cumple $\mathbf{v}^\top H\mathbf{v} = \frac{1}{n}\sum_i p_i(1-p_i)\,(\tilde{\mathbf{x}}_i^\top\mathbf{v})^2 \geq 0$, así que H es semidefinida positiva y J es *convexa*: todo mínimo local es global. Si $\tilde{X}$ tiene rango completo por columnas, H es definida positiva, J es estrictamente convexa y el mínimo es único. Una consecuencia práctica es que el resultado no depende de la inicialización, a diferencia de la red, cuya pérdida no es convexa. Existe una salvedad estadística: si las clases son perfectamente separables por alguna combinación lineal de las variables, el máximo de verosimilitud no existe (los coeficientes divergen); la penalización de la sección 4.1.10 lo evita.

Albert y Anderson 1984

LGD: error cuadrático medio (modelo gaussiano). Aquí $y \in [0,1]$ es la fracción perdida. Se supone $y \mid \mathbf{x} \sim \mathcal{N}(\hat{y}, s^2)$ con s^2 fija:

$$-\log L(\theta) = \frac{n}{2}\log(2\pi s^2) + \frac{1}{2s^2}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

El primer término y el factor $1/(2s^2)$ no dependen de θ, así que maximizar la verosimilitud es minimizar:

$$J(\theta) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

LGD alternativa: entropía cruzada fraccional (cuasi-Bernoulli). Es la misma fórmula de la sección 4.1.5, pero con $y \in [0,1]$ en lugar de $\{0,1\}$. No es una verosimilitud propia, sino una cuasi-verosimilitud. Aun así, su mínimo cumple $E[y \mid \mathbf{x}] = \hat{y}$, así que la red aprende la LGD media. Está disponible con `perdida = entropia_cruzada`. El modelo final usa ECM.

Goodfellow, Bengio y Courville 2016, secs. 5.5 y 6.2.1, Bishop 2006, secs. 3.1.1 y 4.3.2, Papke y Wooldridge 1996

4.1.6. Retropropagación

La retropropagación aplica la regla de la cadena desde la salida hacia la entrada. Calcula todos los gradientes en una sola pasada. Se define el error de la capa l como $\delta^{[l]} = \partial J/\partial Z^{[l]}$.

Paso 1: capa de salida.

$$\text{Entropía cruzada + sigmoide:}\quad \delta^{[L]} = \frac{1}{n}\big(A^{[L]} - \mathbf{y}\big)$$

$$\text{ECM:}\quad \delta^{[L]} = \frac{2}{n}\big(A^{[L]} - \mathbf{y}\big) \odot g_L'\Big(Z^{[L]}\Big)$$

Con entropía cruzada, la derivada de la sigmoide se cancela con la del logaritmo. El error queda simplemente como predicho menos observado.

Paso 2: gradientes de la capa l. El término $\lambda W^{[l]}$ viene de la penalización L2 (sección 4.1.10).

$$\frac{\partial J}{\partial W^{[l]}} = A^{[l-1]\top}\,\delta^{[l]} + \lambda W^{[l]}, \qquad \frac{\partial J}{\partial \mathbf{b}^{[l]}} = \sum_i \delta^{[l]}_{i,\cdot}$$

Paso 3: paso a la capa anterior. El símbolo $\odot$ es el producto elemento a elemento. Si hubo dropout en $A^{[l-1]}$, el gradiente se multiplica por la misma máscara.

$$\delta^{[l-1]} = \left(\delta^{[l]}\,W^{[l]\top}\right) \odot g'\left(Z^{[l-1]}\right)$$

Verificación. Los gradientes se comprobaron con diferencias finitas centradas, $[J(\theta+\varepsilon) - J(\theta-\varepsilon)]/2\varepsilon$. El error relativo es del orden de 10^{-7}.

Caso de la regresión logística ($L = 1$). No hay capas anteriores, así que el paso 3 no se usa. Con $A^{[0]} = X$, $A^{[1]} = \mathbf{p}$ y $\delta^{[1]} = \frac{1}{n}(\mathbf{p} - \mathbf{y})$, el paso 2 da $\partial J/\partial \mathbf{w} = X^\top \delta^{[1]}$ y $\partial J/\partial b = \frac{1}{n}\sum_i (p_i - y_i)$ (más $\lambda \mathbf{w}$ si hay penalización L2), que es el gradiente ∇J de la sección 4.1.5. La retropropagación se reduce a una sola aplicación de la regla de la cadena.

Rumelhart, Hinton y Williams 1986, Goodfellow, Bengio y Courville 2016, sec. 6.5

4.1.7. Optimizador de la red: Adam

El optimizador de la red es Adam (Kingma y Ba, 2015), con mini-lotes. Cada parámetro recibe su propio tamaño de paso: avanza más donde el gradiente es estable y menos donde es ruidoso. En el paso t, con gradiente g_t:

$$\begin{aligned}
m_t &= \beta_1 m_{t-1} + (1-\beta_1)\,g_t && \text{(promedio del gradiente)}\\
v_t &= \beta_2 v_{t-1} + (1-\beta_2)\,g_t^2 && \text{(promedio del gradiente al cuadrado)}\\
\hat m_t &= \frac{m_t}{1-\beta_1^t}, \quad \hat v_t = \frac{v_t}{1-\beta_2^t} && \text{(corrección de sesgo: } m_0 = v_0 = 0\text{)}\\
\theta_t &= \theta_{t-1} - \eta\,\frac{\hat m_t}{\sqrt{\hat v_t} + \varepsilon}
\end{aligned}$$

Tabla 2

Parámetros de los modelos

Parámetro	PD	LGD
Tasa η	0.0026	0.001
β_1, β_2, ε	0.9, 0.999, 10^{-8}	0.9, 0.999, 10^{-8}
Tamaño de lote	512	256
Épocas máximas	200	200

Nota. PD = probabilidad de incumplimiento; LGD = pérdida dado el incumplimiento; η = tasa de aprendizaje.

Kingma y Ba 2015

4.1.8. Optimizadores de la regresión logística

Como J es convexa y diferenciable, la regresión logística se ajusta con métodos deterministas de segundo orden (o cuasi-segundo orden) y no necesita elegir tasa de aprendizaje, tamaño de lote ni épocas. Se usaron tres métodos, que se detienen cuando la norma del gradiente (o el cambio relativo de los coeficientes, en SAGA) cae por debajo de una tolerancia.

Newton-Raphson (mínimos cuadrados reponderados iterativamente). Se usó en el modelo sin penalizar que sirve para la inferencia (sección 4.1.9). Aproxima J por su desarrollo de segundo orden en θ_k y salta al mínimo de esa parábola:

$$\theta_{k+1} = \theta_k - H(\theta_k)^{-1}\nabla J(\theta_k) = \theta_k + \left(\tilde{X}^\top W_k \tilde{X}\right)^{-1}\tilde{X}^\top(\mathbf{y} - \mathbf{p}_k),$$

donde el factor $1/n$ de ∇J y de H se cancela. Esta iteración equivale a resolver un problema de mínimos cuadrados ponderados con pesos W_k y respuesta de trabajo $\boldsymbol{\zeta}_k = \tilde{X}\theta_k + W_k^{-1}(\mathbf{y} - \mathbf{p}_k)$:

$$\theta_{k+1} = \left(\tilde{X}^\top W_k \tilde{X}\right)^{-1}\tilde{X}^\top W_k\, \boldsymbol{\zeta}_k,$$

lo cual puede verificarse sustituyendo $\boldsymbol{\zeta}_k$. Cerca del óptimo converge cuadráticamente.

L-BFGS. Se usó en el modelo con penalización L2. Evita calcular y invertir H, que cuesta $O(d^3)$: avanza en la dirección $\mathbf{d}_k = -B_k\nabla J(\theta_k)$ con un tamaño de paso α_k elegido por búsqueda lineal (condiciones de Wolfe),

$$\theta_{k+1} = \theta_k + \alpha_k \mathbf{d}_k,$$

donde B_k aproxima la inversa de la hessiana con información de los pasos recientes. Con $\mathbf{s}_k = \theta_{k+1} - \theta_k$, $\mathbf{y}_k = \nabla J(\theta_{k+1}) - \nabla J(\theta_k)$ y $\rho_k = 1/(\mathbf{y}_k^\top \mathbf{s}_k)$, la actualización BFGS es

$$B_{k+1} = \left(I - \rho_k \mathbf{s}_k \mathbf{y}_k^\top\right) B_k \left(I - \rho_k \mathbf{y}_k \mathbf{s}_k^\top\right) + \rho_k \mathbf{s}_k \mathbf{s}_k^\top,$$

que cumple la condición de secante $B_{k+1}\mathbf{y}_k = \mathbf{s}_k$. La versión de memoria limitada (L-BFGS) no almacena B_k: guarda solo las últimas m parejas $(\mathbf{s}_k, \mathbf{y}_k)$ y calcula el producto $B_k\nabla J$ con una recursión de dos bucles, con costo lineal en d.

SAGA (penalización L1). La norma ℓ_1 no es diferenciable en cero, así que se usa un método proximal. Con una pérdida f suave y un término $r(\mathbf{w}) = \lambda\|\mathbf{w}\|_1$, SAGA combina un gradiente estocástico con memoria, $\mathbf{g}_t = \nabla f_j(\mathbf{w}_t) - \nabla f_j(\boldsymbol{\varphi}_j) + \bar{\mathbf{g}}$ (donde $\boldsymbol{\varphi}_j$ es el último punto en que se evaluó el gradiente del crédito j y $\bar{\mathbf{g}}$ el promedio de los gradientes guardados), y aplica el operador proximal de la norma ℓ_1, la umbralización suave:

$$\mathbf{w}_{t+1} = \operatorname{prox}_{\gamma r}\left(\mathbf{w}_t - \gamma\, \mathbf{g}_t\right), \qquad \left[\operatorname{prox}_{\gamma\lambda\|\cdot\|_1}(\mathbf{u})\right]_j = \operatorname{sign}(u_j)\,\max\left(|u_j| - \gamma\lambda,\, 0\right).$$

Los coeficientes cuyo valor absoluto queda por debajo del umbral se anulan exactamente, lo que produce soluciones dispersas.

Los tres métodos minimizan el mismo objetivo convexo, por lo que, si convergen, llegan al mismo mínimo.

Nelder y Wedderburn 1972; Nocedal y Wright 2006; Liu y Nocedal 1989; Defazio, Bach y Lacoste-Julien 2014; implementaciones: Pedregosa et al. 2011; Seabold y Perktold 2010

4.1.9. Inferencia sobre los coeficientes de la regresión logística

Los errores estándar, los intervalos de confianza y las pruebas de hipótesis son válidos para el modelo *sin penalizar*, ajustado por máxima verosimilitud. Para el enlace canónico, la información de Fisher observada y esperada coinciden y valen $I(\theta) = \tilde{X}^\top W \tilde{X} = nH(\theta)$. Bajo condiciones de regularidad y con n grande, el estimador es aproximadamente normal:

$$\hat{\theta} \overset{a}{\sim} \mathcal{N}\left(\theta_0,\ I(\theta_0)^{-1}\right), \qquad \widehat{\operatorname{Var}}(\hat{\theta}) = \left(\tilde{X}^\top \hat{W} \tilde{X}\right)^{-1},$$

y el error estándar de $\hat{w}_j$ es la raíz del elemento diagonal correspondiente, EE_j. De ahí se obtienen:

- **Intervalo de Wald** del 95 %: $\hat{w}_j \pm 1{,}96\,\mathrm{EE}_j$. Como exp es creciente, el intervalo de la razón de odds es $\left[e^{\hat{w}_j - 1{,}96\,\mathrm{EE}_j},\ e^{\hat{w}_j + 1{,}96\,\mathrm{EE}_j}\right]$.
- **Prueba de Wald** de $H_0: \ w_j = 0$: $z_j = \hat{w}_j/\mathrm{EE}_j \overset{a}{\sim} \mathcal{N}(0,1)$ bajo H_0, con valor-p igual a $2\big(1 - \Phi(|z_j|)\big)$.
- **Prueba de razón de verosimilitud** para comparar un modelo reducido con uno completo que añade q términos (por ejemplo, un cuadrado o una interacción): $\Lambda = 2\big(\ell_{\text{completo}} - \ell_{\text{reducido}}\big) \overset{a}{\sim} \chi^2_q$ bajo H_0, con $\ell = -nJ$ evaluada en el óptimo de cada modelo.

Como diagnóstico de colinealidad se usa el factor de inflación de la varianza,

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2},$$

donde R_j^2 es el coeficiente de determinación de la regresión de x_j sobre las demás variables explicativas. Mide cuántas veces se infla la varianza de $\hat{w}_j$ por la correlación de x_j con las demás; en regresión logística se calcula sobre las variables explicativas y es un indicador aproximado. Para revisar el supuesto de linealidad en el logit se compara, por deciles de una variable, el logit de la tasa de malos observada con el valor medio de la variable.

Hosmer, Lemeshow y Sturdivant 2013; Belsley, Kuh y Welsch 1980

4.1.10. Regularización

La red combina tres técnicas para evitar el sobreajuste: L2, dropout y parada temprana. La regresión logística usa solo la penalización L2 (con L1 como comparación).

Penalización L2 (weight decay). Se suma al objetivo un costo por pesos grandes. Los sesgos no se penalizan. Valores usados en la red: $\lambda = 0{,}0014$ en PD y 0,0001 en LGD.

$$J_{\text{reg}}(\theta) = J(\theta) + \frac{\lambda}{2}\sum_{l=1}^{L}\left\|W^{[l]}\right\|_F^2 \quad \Rightarrow \quad \text{gradiente extra: } \lambda W^{[l]}$$

Equivale, en la estimación por máximo a posteriori (MAP), a poner un prior gaussiano $\mathcal{N}(0, \tau^2)$ sobre los pesos. En efecto, multiplicando J_{reg} por n queda $-\ell(\theta) + \frac{n\lambda}{2}\|W\|_F^2$, y el logaritmo negativo de un prior gaussiano es $\|W\|_F^2/(2\tau^2)$ más una constante; igualando, $\tau^2 = 1/(n\lambda)$ (con J promedio; si J fuera la suma, sería $1/\lambda$).

Dropout invertido. Al entrenar, cada neurona oculta se apaga con probabilidad p. Las que sobreviven se escalan por $1/(1-p)$, así que $E[\tilde{a}] = a$ y al predecir se usa la red completa sin cambios. Valores usados: $p = 0{,}3$ en PD y 0,1 en LGD.

$$\tilde{A}^{[l]} = A^{[l]} \odot \frac{M^{[l]}}{1-p}, \qquad M_{ij}^{[l]} \sim \text{Bernoulli}(1-p)$$

Parada temprana. Después de cada época se mide J en validación, sin la penalización. Si no mejora en 10 épocas seguidas, el entrenamiento se detiene y se recuperan los pesos de la mejor época.

Regularización en la regresión logística: L2 y L1. El modelo de referencia se ajusta con la parametrización de `scikit-learn`, que multiplica la pérdida por un parámetro $C > 0$ (inverso de la fuerza de regularización) en lugar de multiplicar la penalización:

$$\text{L2:}\ \min_{b,\mathbf{w}}\ C\sum_{i=1}^{n}\ell_i(b,\mathbf{w})+\tfrac{1}{2}\|\mathbf{w}\|_2^2, \qquad \text{L1:}\ \min_{b,\mathbf{w}}\ C\sum_{i=1}^{n}\ell_i(b,\mathbf{w})+\|\mathbf{w}\|_1,$$

con $\ell_i = \log(1+e^{z_i}) - y_i z_i$ y el sesgo b sin penalizar. Dividiendo por Cn se obtiene la forma con pérdida promedio de la red, $J(\theta)+\frac{\lambda}{2}\|\mathbf{w}\|_2^2$ (L2) o $J(\theta)+\lambda\|\mathbf{w}\|_1$ (L1), con

$$\lambda = \frac{1}{Cn}.$$

Un C grande equivale a una penalización débil y, en el límite, al modelo sin penalizar.

La penalización admite una lectura bayesiana. Con un prior gaussiano $w_j \sim \mathcal{N}(0,\tau^2)$ se tiene

$$-\log\pi(\mathbf{w}) = \frac{\|\mathbf{w}\|_2^2}{2\tau^2} + \text{cte},$$

y el objetivo MAP, $\sum_i \ell_i + \|\mathbf{w}\|_2^2/(2\tau^2)$, coincide con el de L2 cuando $\tau^2 = C$. Con un prior de Laplace de escala s,

$$-\log\pi(\mathbf{w}) = \frac{\|\mathbf{w}\|_1}{s} + \text{cte},$$

y el objetivo coincide con el de L1 cuando $s = C$. El sesgo b no se penaliza, lo que equivale a un prior plano.

El efecto de cada penalización es distinto. L2 encoge los coeficientes hacia cero sin anularlos, reduce su varianza (a costa de algo de sesgo) y estabiliza el ajuste con variables correlacionadas: en el paso de Newton, $\tilde{X}^\top W\tilde{X}$ se reemplaza por $\tilde{X}^\top W\tilde{X} + n\lambda D$ con $D = \text{diag}(0,1,\ldots,1)$, que es definida positiva aunque haya colinealidad. L1 anula exactamente los coeficientes cuyo efecto no supera el umbral, porque su penalización no es diferenciable en cero (sección 4.1.8). Como la penalización depende de la escala de cada variable, las variables numéricas se estandarizan con la media y la desviación del entrenamiento antes de ajustar. El parámetro C se elige en validación, minimizando la pérdida logarítmica, sobre una rejilla logarítmica de 10^{-4} a 10^{2} (13 valores) para cada penalización.

Hoerl y Kennard 1970; Tibshirani 1996, Bishop 2006, cap. 3

Krogh y Hertz 1992; Srivastava et al. 2014; Prechelt 1998, Goodfellow, Bengio y Courville 2016, cap. 7

4.1.11. Métricas de evaluación

La PD se evalúa por discriminación y calibración. La LGD se evalúa por error y por qué tan parecida es la distribución predicha a la observada.

PD (clasificación). AUC. Es la probabilidad de que un malo al azar tenga una p mayor que un bueno al azar. Se calcula con los rangos de Mann–Whitney: n_1 es el número de malos, n_0 el de buenos y R_1 la suma de los rangos de los malos (ordenados por p creciente, con rangos promedio en los empates, que equivale a contar $1/2$ por empate).

$$\text{AUC} = P(p_{\text{malo}} > p_{\text{bueno}}) = \frac{R_1 - n_1(n_1+1)/2}{n_1 n_0}$$

Gini. Es la AUC reescalada para que el azar valga 0 y la separación perfecta valga 1.

$$\text{Gini} = 2\,\text{AUC} - 1$$

KS. Es la máxima separación entre las distribuciones acumuladas de p para malos y para buenos. Equivale a la máxima diferencia entre la tasa de verdaderos positivos y la de falsos positivos.

$$\mathrm{KS} = \max_t \left| F_{\text{malos}}(t) - F_{\text{buenos}}(t) \right| = \max_t \left[\mathrm{TPR}(t) - \mathrm{FPR}(t) \right]$$

Brier. Es el error cuadrático de la probabilidad. Mide calibración y discriminación a la vez.

$$\mathrm{Brier} = \frac{1}{n} \sum_{i=1}^{n} (p_i - y_i)^2$$

Brier de referencia y Brier skill score. Como el Brier depende de la tasa de malos, se compara con el de un predictor constante igual a la tasa de malos del entrenamiento, $\bar{\pi}_{\text{ent}}$. Si π es la tasa observada en la muestra evaluada,

$$\mathrm{Brier}_{\text{ref}} = \frac{1}{n} \sum_{i=1}^{n} \left(\bar{\pi}_{\text{ent}} - y_i \right)^2 = \pi(1-\pi) + \left(\bar{\pi}_{\text{ent}} - \pi \right)^2, \qquad \mathrm{BSS} = 1 - \frac{\mathrm{Brier}}{\mathrm{Brier}_{\text{ref}}}.$$

La igualdad se obtiene desarrollando el cuadrado con $\frac{1}{n}\sum y_i = \pi$ y $y_i^2 = y_i$. El BSS vale 0 si el modelo no mejora al predictor constante y 1 si es perfecto.

Entropía cruzada. Es la misma pérdida de la sección 4.1.5 medida en test: el promedio de $-$ log-verosimilitud.

Curva de calibración. Se ordenan los créditos en 10 grupos por p. En cada grupo se compara la p promedio con la tasa de malos observada. Si el modelo está bien calibrado, los puntos quedan sobre la diagonal.

Intervalo de Wilson para cada grupo. Para un grupo con m créditos y k malos, con $\hat{q} = k/m$ y $z = 1{,}96$, la tasa observada se acompaña del intervalo

$$\frac{\hat{q} + \dfrac{z^2}{2m}}{1 + \dfrac{z^2}{m}} \;\pm\; \frac{z}{1 + \dfrac{z^2}{m}} \sqrt{\frac{\hat{q}(1-\hat{q})}{m} + \frac{z^2}{4m^2}},$$

que, a diferencia del intervalo normal, se mantiene dentro de $[0, 1]$ y es fiable con proporciones pequeñas.

Pendiente e intercepto de calibración. Con $\hat{z}_i = \ln \frac{\hat{p}_i}{1-\hat{p}_i}$, se ajusta por máxima verosimilitud en la muestra evaluada el modelo logístico

$$\ln \frac{P(y_i = 1)}{P(y_i = 0)} = a + c\, \hat{z}_i.$$

Una calibración perfecta corresponde a $a = 0$ y $c = 1$. Una pendiente $c < 1$ indica probabilidades demasiado extremas (típica del sobreajuste) y $c > 1$, demasiado moderadas. Como medida del nivel medio se estima el *desplazamiento* a^* con la pendiente fija en 1, es decir, el valor que resuelve $\sum_i \left[y_i - \sigma(a^* + \hat{z}_i) \right] = 0$ (la ecuación de verosimilitud del intercepto con $\hat{z}_i$ como término fijo). Con ese desplazamiento, la probabilidad media predicha iguala la tasa observada; $a^* > 0$ indica que el modelo subestima el riesgo en promedio. El mismo desplazamiento, estimado en validación, permite recalibrar las probabilidades de prueba.

Intervalos *bootstrap*. Para cuantificar la incertidumbre de una métrica m se remuestrean $B = 1000$ veces los n créditos con reemplazo, se recalcula la métrica en cada remuestra, $m^{*(1)}, \ldots, m^{*(B)}$, y se toma el intervalo entre los percentiles 2.5 y 97.5 de esos valores. Así se comparan dos modelos sin suponer una distribución para el estadístico.

LGD (regresión).

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|, \qquad \text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

KS de dos muestras. Mide la distancia entre la distribución de la LGD observada y la de la predicha. Se acompaña con la media, la desviación y los cuantiles de ambas.

$$D = \max_t \left|F_y(t) - F_{\hat{y}}(t)\right|$$

Hanley y McNeil 1982; Mann y Whitney 1947; Brier 1950; Massey 1951; Niculescu-Mizil y Caruana 2005; calibración y remuestreo: Cox 1958; Wilson 1927; Efron 1979

4.1.12. Derivación de la scorecard

El puntaje es una función lineal del logaritmo de las odds buenos : malos. Un puntaje alto significa menos riesgo:

$$\text{odds} = \frac{1-p}{p}, \qquad \text{Puntaje} = \text{offset} + \text{factor}\cdot\ln(\text{odds})$$

Dos condiciones fijan las constantes. Con los valores del proyecto: puntaje base 600, odds base 50:1 y PDO = 20.

1. Las odds base 50 valen 600 puntos: $600 = \text{offset} + \text{factor}\cdot\ln 50$.
2. Duplicar las odds suma PDO = 20 puntos: $620 = \text{offset} + \text{factor}\cdot\ln 100$.

Al restar (2) − (1) se obtiene $\text{factor}\cdot\ln 2 = \text{PDO}$:

$$\text{factor} = \frac{\text{PDO}}{\ln 2} = \frac{20}{\ln 2} \approx 28{,}85, \qquad \text{offset} = 600 - \text{factor}\cdot\ln 50 \approx 487{,}12$$

Relación con la red y con la regresión logística. Como $p = \sigma(z)$, se tiene $\ln\big((1-p)/p\big) = -z$. Por eso el puntaje es lineal en la preactivación de la salida:

$$\text{Puntaje} = \text{offset} - \text{factor}\cdot z \qquad \Longleftrightarrow \qquad p = \frac{1}{1+\exp\big((\text{Puntaje}-\text{offset})/\text{factor}\big)}$$

Puntos por variable. Cada variable aporta puntos frente a un solicitante de referencia $\mathbf{x}_{\text{ref}}$, el promedio de entrenamiento:

$$\text{puntos}_j(\mathbf{x}) = \text{Puntaje}(\mathbf{x}) - \text{Puntaje}\big(\mathbf{x} \text{ con } x_j = x_{\text{ref},j}\big)$$

- **Regresión logística:** $z = b + \sum_j w_j x_j$, así que $\text{puntos}_j = -\text{factor}\cdot w_j\,(x_j - x_{\text{ref},j})$. Los puntos suman exactamente el total, como en la scorecard aditiva clásica.
- **Red neuronal:** z no es aditivo. Lo que sobra, $\text{total} - \text{base} - \sum_j \text{puntos}_j$, mide el efecto de las interacciones entre variables.

Siddiqi 2006; Thomas, Edelman y Crook 2002

4.2. Caso de uso

El modelo está pensado para que lo use una entidad que otorga créditos a 36 meses. Estima, para cada solicitante, la probabilidad de que su crédito resulte malo, es decir, que termine en incumplimiento en lugar de pagarse por completo. Con esa probabilidad, la entidad decide si aprueba o rechaza la solicitud: el modelo no decide por sí solo, sino que entrega una probabilidad que la entidad compara con el umbral definido por su política de riesgo.

El modelo se aplica en el momento de la solicitud, una vez que el cliente ha entregado sus datos y la entidad ha consultado su reporte en el buró de crédito, y antes del desembolso. La decisión se toma una sola vez, con lo que se conoce ese día. Por eso el modelo solo utiliza información disponible en ese instante: los datos que el cliente declara y las variables de su historial crediticio.

Información disponible en ese instante: Los datos de la solicitud son el monto del crédito solicitado por el cliente, su antigüedad laboral en años, su situación de vivienda, su ingreso anual declarado y el propósito del crédito. Las variables del historial en el buró de crédito son la relación entre sus pagos mensuales de deuda y su ingreso mensual, el número de moras de 30 días o más en los últimos dos años, el mes de apertura de su línea de crédito más antigua, el número de consultas de crédito en los últimos seis meses, los meses transcurridos desde su última mora, el número de líneas de crédito abiertas, el número de registros públicos negativos, el saldo del crédito rotativo, el porcentaje utilizado de ese crédito rotativo y el número total de líneas de crédito en su historial.

4.3. Preprocesamiento de datos

Valores nulos y ceros contradictorios

Antes de definir el preprocesamiento, se revisó en qué variables y en qué momentos faltan datos, y si algunos ceros corresponden a valores reales o a códigos que reemplazan un dato ausente. Las revisiones sobre la codificación a lo largo del tiempo se hicieron con la base completa (todos los plazos y años), porque solo así es posible detectar cambios entre años; las revisiones que sustentan imputaciones o recodificaciones se hicieron con el conjunto de entrenamiento.

Nulos por año de originación

La Tabla 3 muestra, para las variables con algún valor ausente, la proporción de nulos por año de originación. Se identificaron cuatro patrones.

Tabla 3

Porcentaje de valores nulos por año de originación

Variable	2007	2008	2009	2010	2011	2012	2013	2014	2015
Historial crediticio[a]	4,8	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
annual_inc	0,7	0,0	0,0	0,0	0,0	0,0	0,0	0,0	0,0
emp_length	0,0	0,0	0,0	2,8	3,5	3,6	4,4	5,1	5,7
revol_util	5,3	0,5	0,3	0,2	0,0	0,1	0,1	0,1	0,0
mths_since_last_delinq	6,5	38,1	67,0	64,3	66,2	58,8	56,5	49,2	48,4

1. **Historial crediticio.** Seis variables (delinq_2yrs, earliest_cr_line, inq_last_6mths, open_acc, pub_rec y total_acc) tienen nulos únicamente en 2007, con la misma proporción (4,8 %). Esa proporción equivale a unos 29 de los 603 créditos originados ese año, que es la misma cantidad que se elimina del conjunto de entrenamiento. Es consistente con que se trate de solicitantes sin historial crediticio, a quienes les faltan todas estas variables a la vez.

2. **Antigüedad laboral.** `emp_length` no tiene nulos de 2007 a 2009, y desde 2010 su proporción de nulos crece cada año, de 2,8 %a 5,7 %en 2015. Es decir, la ausencia de este dato depende de la fecha de originación.

3. **Ingreso anual.** `annual_inc` tiene nulos solo en 2007 (0,7 %); en entrenamiento son 4 créditos.

4. **Meses desde la última mora.** La proporción de nulos de `mths_since_last_delinq` cambia de forma abrupta: 6,5 %en 2007, 38,1 %en 2008 y alrededor de 60 %a partir de 2009. Un cambio de esta magnitud no se explica por el comportamiento de los clientes, sino por la forma de codificar los datos, como se muestra más adelante.

`mths_since_last_delinq`: el significado del nulo y del cero

El nulo equivale a "sin mora registrada". La Tabla 4 cruza la existencia de una mora en los últimos dos años (`delinq_2yrs`) con la presencia de un valor en `mths_since_last_delinq`, en el conjunto de entrenamiento. Los 3.508 créditos con alguna mora reciente tienen siempre un valor, es decir, ninguno tiene nulo. Entre los 27.997 créditos sin mora reciente, 19.717 (70,4 %) tienen nulo y 8.280 (29,6 %) tienen un valor, que corresponde a una mora anterior a los dos últimos años. Por tanto, el nulo aparece solo cuando no hay mora reciente, y se interpreta como ausencia de mora registrada.

Tabla 4
Presencia del historial de moras recientes

	`mths_since_last_delinq` nulo	Con valor	Total
`delinq_2yrs` $= 0$	19.717 (70,4 %)	8.280 (29,6 %)	27.997
`delinq_2yrs` > 0	0 (0,0 %)	3.508 (100,0 %)	3.508

Nota. Muestra de entrenamiento ($n = 31{,}505$).

El cero es un código en los primeros años. Un valor de cero meses desde la última mora implicaría una mora reciente y, por tanto, `delinq_2yrs` ≥ 1. La Tabla 5 muestra, con la base completa, que de los 1.723 créditos con cero, 821 (47,6 %) tienen `delinq_2yrs` $= 0$, lo cual es contradictorio. Además, estos ceros no están repartidos en el tiempo: representan el 60,1 %de los créditos de 2007 y el 19,8 %de los de 2008, y son prácticamente nulos desde 2009 (Tabla 6). En entrenamiento hay 821 ceros, de los cuales solo 1 tiene `delinq_2yrs` > 0; es decir, 820 son contradictorios.

Tabla 5
Moras recientes según meses desde la última mora

	`delinq_2yrs` $= 0$	`delinq_2yrs` > 0
`mths_since_last_delinq` $= 0$	821	902
`mths_since_last_delinq` $\neq 0$ o nulo	716.140	169.487

Nota. Base completa; créditos con historial ($n = 887{,}350$).

Los nulos y los ceros se compensan. La Tabla 6 suma, año por año, la proporción de nulos y la de ceros. Mientras los nulos por sí solos varían entre 6,5 %y 67,0 %, su suma oscila entre 57,9 %y 67,0 %de 2007 a 2012. Esto indica que en los primeros años la ausencia de mora se registraba con un cero y que, a partir de 2009, se registra con un nulo. Fuera de ese periodo, la suma baja a 48,5 %–56,6 %en 2013–2015, años que no forman parte de la población de estudio.

Tabla 6
Porcentaje de valores nulos y ceros por año de originación

Año	Nulo	Igual a 0	Nulo o igual a 0
2007	6,5	60,1	66,6
2008	38,1	19,8	57,9
2009	67,0	0,0	67,0
2010	64,3	0,0	64,3
2011	66,2	0,0	66,2
2012	58,8	0,0	58,8
2013	56,5	0,1	56,6
2014	49,2	0,1	49,3
2015	48,4	0,1	48,5

Nota. Base completa. Los valores se expresan en porcentajes. El porcentaje de nulos se calcula sobre todos los créditos del año y el de ceros sobre los créditos con historial; por ello, la suma de 2007 es aproximada.

Implicación. Un cero en `mths_since_last_delinq` con `delinq_2yrs` $= 0$ no es un tiempo real, sino el código de "sin mora". Si no se corrigiera, la variable mezclaría dos significados distintos bajo el mismo valor.

`mths_since_last_record`: el cero como código

Con el mismo razonamiento, un cero en `mths_since_last_record` significaría un registro público ocurrido el mismo mes de la originación, por lo que se esperaría `pub_rec` ≥ 1. La Tabla 7 muestra lo contrario en entrenamiento. Los 1.275 créditos con cero tienen todos `pub_rec` $= 0$, y los 1.728 con un valor positivo tienen todos `pub_rec` ≥ 1; no hay ningún caso fuera de esas dos combinaciones. El cero es, por tanto, un código de "sin registro público".

Tabla 7
Presencia de registros públicos según meses desde el último registro

	`pub_rec` $= 0$	`pub_rec` > 0
`mths_since_last_record` $= 0$	1.275	0
`mths_since_last_record` > 0	0	1.728

Nota. Muestra de entrenamiento, limitada a créditos con valor en `mths_since_last_record` ($n = 3{,}003$).

Al igual que en la variable anterior, este código solo aparece en los primeros años. En toda la base, los créditos con valor en `mths_since_last_record` y `pub_rec` $= 0$ son 1.275 (Tabla 8): 524 de 2007, 748 de 2008 y 3 de 2009, ninguno posterior. Como su número coincide con el de entrenamiento, son exactamente los mismos créditos.

Tabla 8
Créditos con valor en meses desde el último registro y cero registros públicos, por año

Año	Créditos
2007	524
2008	748
2009	3
Total	1.275

Nota. Base completa.

Implicación. Como el cero es un código propio de 2007–2009 y como, además, la existencia

de registros públicos ya está recogida por `pub_rec`, la variable no aporta información adicional y su codificación cambia con el tiempo.

`revol_util`:nulos y rango

En el conjunto de entrenamiento sin procesar, `revol_util` tiene 86 valores nulos. Los 29 créditos sin historial crediticio, que se excluyen del análisis, tienen todos `revol_util` nulo; ellos explican 4,8 de los 5,3 puntos porcentuales de nulos que presenta 2007 en la Tabla 3. Los 57 nulos restantes corresponden a créditos con historial y son los que efectivamente requieren tratamiento. De ellos, 55 (96,5 %) tienen saldo rotativo `revol_bal` igual a cero, de modo que no hay crédito rotativo sobre el cual calcular la utilización; los 2 restantes tienen saldo positivo, y uno de ellos (290.291) concentra la mayor parte del saldo de este grupo.

Implicación. Los nulos de `revol_util` no tienen un único significado. Cuando el saldo rotativo es cero, la utilización no está definida porque no hay crédito rotativo. Cuando el saldo es positivo, la utilización existe pero no se observa, y entre las variables seleccionadas no se dispone del límite de crédito para reconstruirla. Por eso los dos casos requieren un tratamiento distinto.

Rango de `dti` y `revol_util`

La Tabla 9 resume la distribución de ambas variables. En entrenamiento, el mínimo de `dti` es 0, por lo que no hay valores negativos, y su máximo es 29,99. `revol_util` tiene un mínimo de 0 (al menos el 1 %de los créditos tiene utilización nula) y un máximo de 119, que supera el 100 %pero es posible cuando el saldo excede el límite de crédito.

Validación y prueba muestran un desplazamiento hacia mayor endeudamiento. La media de `dti` pasa de 13,07 en entrenamiento a 14,85 en validación y 17,25 en prueba, y sus máximos (34,92 y 34,99) superan el máximo observado en entrenamiento. La mediana de `revol_util` sube de 48,1 a 60,8 y 59,9. Esta comparación es solo una verificación: no se tomó ninguna decisión de limpieza a partir de validación ni de prueba.

Tabla 9

Estadísticos de endeudamiento y utilización de crédito por partición

Variable	Partición	n	Media	Mediana	P99	P99,9	Mín.	Máx.
`dti`	Entrenamiento	31.534	13,07	13,10	26,70	29,47	0,00	29,99
`dti`	Validación	14.967	14,85	14,90	29,83	34,00	0,00	34,92
`dti`	Prueba	28.458	17,25	16,94	33,88	34,88	0,00	34,99
`revol_util`	Entrenamiento	31.448	48,03	48,10	98,70	99,90	0,00	119,00
`revol_util`	Validación	14.947	56,68	60,80	96,70	99,10	0,00	99,90
`revol_util`	Prueba	28.437	57,63	59,90	96,40	98,06	0,00	104,40

Nota. Estadísticos calculados con los datos sin procesar. P99 y P99,9 corresponden a los percentiles 99 y 99,9, respectivamente.

El preprocesamiento transforma los datos originales en la matriz de diseño que utilizan los modelos. Se guió por tres principios. Primero, se separaron las *reglas fijas*, que no dependen de los datos y producen el mismo resultado en cualquier partición, de los *parámetros aprendidos* (medianas, percentiles, medias, desviaciones estándar y categorías), que se estimaron únicamente con el conjunto de entrenamiento y luego se aplicaron sin modificación a validación y prueba. Si estos estadísticos se calcularan con toda la base, la información de validación y prueba intervendría en la construcción de las variables (fuga de datos) y el desempeño estimado sería optimista; además, como la partición es temporal, usar parámetros de periodos posteriores equivaldría a usar información del futuro. Con el procedimiento adoptado, el modelo se evalúa en las mismas condiciones en que operaría con un solicitante nuevo, para el cual solo existen parámetros estimados con datos pasados. Segundo, cada decisión se sustentó en evidencia empírica obtenida en los hallazgos anteriores. Tercero, el mismo conjunto de variables

alimenta el modelo logístico y la red neuronal, de modo que las diferencias de desempeño se deban al modelo y no a los datos de entrada.

La Tabla 10 resume el tratamiento de cada variable y su tipo.

Tabla 10
Tratamiento de cada variable y tipo de operación

Variable	Tratamiento	Tipo
`term`	Eliminada (constante: 36 meses)	Regla fija
`mths_since_last_record`	Eliminada (cero-código; redundante con `pub_rec`)	Regla fija
Seis variables de historial[a]	Exclusión de créditos sin historial	Regla fija
`loan_amnt`	Estandarización	Parámetros aprendidos
`emp_length`	"$<$ 1 año" $\rightarrow$ 0, "10+" $\rightarrow$ 10, "n/a" $\rightarrow$ nulo; indicadora `emp_length_na`; mediana; estandarización	Fija y aprendida
`home_ownership`	NONE y ANY $\rightarrow$ OTHER; indicadoras con categoría base la más frecuente	Fija y aprendida
`annual_inc`	Mediana para nulos; tope en el percentil 99; $\log(1+x)$; estandarización	Aprendida
`purpose`	Categorías con menos de 1 %$\rightarrow$ "raras"; indicadoras con categoría base la más frecuente	Aprendida
`dti`	Estandarización	Aprendida
`delinq_2yrs`, `inq_last_6mths`, `open_acc`, `total_acc`	Tope en el percentil 99; estandarización	Aprendida
`earliest_cr_line`	Se convierte en `antig_credito_meses` (meses); tope en el percentil 99; estandarización	Fija y aprendida
`mths_since_last_delinq`	Cero con `delinq_2yrs` $= 0 \rightarrow$ nulo; indicadora `nunca_mora`; mediana para nulos; estandarización	Fija y aprendida
`pub_rec`	Tope en 2 (categorías 0, 1 y 2 o más); estandarización	Fija y aprendida
`revol_bal`	Tope en el percentil 99; $\log(1+x)$; estandarización	Aprendida
`revol_util`	Nulo con `revol_bal` $= 0 \rightarrow 0$; nulo con `revol_bal` $> 0 \rightarrow$ mediana; estandarización	Fija y aprendida

Nota. [a] `delinq_2yrs`, `inq_last_6mths`, `pub_rec`, `open_acc`, `total_acc` y `earliest_cr_line`.

4.3.1. Población y variables descartadas

Créditos sin historial crediticio.

Cómo: Se excluyeron los solicitantes a quienes les faltaba alguna de las seis variables de historial; en entrenamiento fueron 29 créditos (0,09 %de 31.534). **Justificación estadística:** Estas variables faltan todas a la vez y la causa del dato ausente es la propia condición de no tener historial. Imputarlas con medianas fabricaría un historial crediticio que no existe y asignaría al solicitante el perfil de un cliente promedio, que no representa a esa población.

`term`.

Cómo: Se eliminó.

Justificación estadística: Tras restringir la población a créditos a 36 meses, la variable es constante. Una columna no aporta información.

`mths_since_last_record`.

Cómo: Se eliminó.

Justificación estadística: Los hallazgos muestran que el cero es un código de "sin registro" y no un tiempo (Tabla 7): los 1.275 créditos con cero tienen todos `pub_rec` $= 0$ y los 1.728 con valor positivo tienen todos `pub_rec` ≥ 1. Además, ese código solo aparece entre 2007 y 2009 (Tabla 8). La variable presenta, por tanto, un error de medición dependiente del tiempo, y su contenido informativo sobre la existencia de registros públicos ya está en `pub_rec`.

4.3.2. Recodificación y construcción de variables

`mths_since_last_delinq` e indicadora `nunca_mora`.

Cómo: Los ceros con `delinq_2yrs` $= 0$ se recodificaron como dato ausente, y se creó la indicadora `nunca_mora`, que vale 1 cuando no hay mora registrada.

Justificación estadística: Los hallazgos (Tablas 4, 5 y 6) muestran que el cero es contradictorio con `delinq_2yrs` $= 0$ y que se concentra en 2007 y 2008, mientras que la suma de nulos y ceros se mantiene estable entre años. Dejar esos ceros como valores reales los situaría en el extremo inferior de la escala, es decir, como "mora reciente", siendo en realidad clientes sin mora. Esto produce un error de clasificación en la covariable, con dos consecuencias: puntos de alto apalancamiento en un extremo de la variable y un coeficiente sesgado, que mezcla el efecto de la mora reciente con el del periodo, los años en que se usó el código. En el conjunto sin filtrar, las tasas de malos de 2007 y 2008 (26,2 %y 20,7 %) superan a la de 2009 (13,7 %), de modo que el riesgo de confusión con el periodo no es menor. Tras la recodificación, `nunca_mora` resulta estable en el tiempo (entre 58 %y 67 %según el año), lo que respalda la regla.

Para qué: Que `mths_since_last_delinq` mida únicamente tiempo transcurrido entre quienes tuvieron mora, y que la ausencia de mora quede representada por una variable propia y estable.

`emp_length`.

Cómo: "$<$ 1 año" se codificó 0, "10+ años" se codificó 10 y "n/a" se trató como dato ausente, con la indicadora `emp_length_na`.

Justificación estadística: La variable es ordinal con once niveles; se trató como numérica, lo que supone un efecto aproximadamente lineal sobre el logit y ahorra diez parámetros frente a una codificación categórica, una ventaja importante para la estabilidad de las estimaciones. El valor 10 representa "diez o más", por lo que la variable está censurada por la derecha; se acepta esa pérdida de información. La ausencia no es ajena al tiempo: es nula hasta 2009 y crece desde 2010 (Tabla 3), de modo que es informativa y no puede asumirse aleatoria. Por eso se conserva con una indicadora. **Para qué:** Reducir dimensionalidad y conservar la información de la ausencia.

`antig_credito_meses`.

Cómo: Se calculó $a = 12(\text{año}_{\text{orig}} - \text{año}_{\text{cr}}) + (\text{mes}_{\text{orig}} - \text{mes}_{\text{cr}})$, la diferencia en meses entre la fecha de originación y la apertura de la primera línea de crédito. Se verificó que ningún valor fuera negativo.

Justificación estadística: Una fecha no tiene interpretación como predictor: su representación numérica es arbitraria y dependería del calendario, no del solicitante. La duración del historial es, en cambio, una medida de experiencia crediticia, continua e interpretable. Se calculó respecto de la fecha de originación y no de la del análisis, de modo que representa la información disponible en el momento de la decisión y es consistente entre particiones. **Para qué:** Obtener una variable con significado económico que no incorpore la fecha de corte.

`home_ownership`. Cómo: Las categorías NONE y ANY se agruparon con OTHER. **Justificación estadística:** El diccionario solo documenta RENT, OWN, MORTGAGE y OTHER; las demás son niveles raros. Con pocas observaciones, y con aún menos malos.

4.3.3. Tratamiento de valores ausentes

`revol_util`. Cómo: Si el valor falta y el saldo rotativo es cero, se fijó en 0; si falta y el saldo es positivo, se imputó con la mediana de entrenamiento. **Justificación estadística:** Los dos casos son distintos. Entre los 57 nulos de créditos con historial, 55 (96,5 %) tienen saldo cero; para ellos la utilización, cociente entre saldo y límite, no existe porque no hay crédito rotativo, y 0 es el valor coherente con la definición. Los 2 restantes sí tienen utilización, pero no se observa, y entre las variables seleccionadas no se dispone del límite para reconstruirla; allí se trata como dato ausente al azar y se imputa con la mediana, que es robusta frente a la asimetría y a valores extremos, a diferencia de la media. Con 2 casos, el efecto sobre la varianza o la asociación es despreciable. **Para qué:** Completar la variable sin introducir valores artificiales en la mayoría

de los casos.

`annual_inc`. **Cómo:** Los nulos (4 créditos en entrenamiento) se imputaron con la mediana de entrenamiento. **Justificación estadística:** La mediana es robusta a la fuerte asimetría del ingreso.

Método del indicador de ausencia (`mths_since_last_delinq` y `emp_length`).

Cómo: Los nulos se reemplazaron por la mediana de entrenamiento y se añadió una indicadora z que vale 1 cuando el dato falta.

Justificación estadística: Sea $x^* = x$ si $z = 0$ y $x^* = c$ (la mediana) si $z = 1$. El modelo

$$\operatorname{logit} P(y = 1) = \beta_0 + \beta_1 x^* + \beta_2 z + \cdots$$

se comporta así: para $z = 0$ la pendiente de x es β_1, estimada solo con los casos observados; para $z = 1$ el nivel del logit es $\beta_0 + \beta_2 + \beta_1 c$, de modo que β_2 recoge la diferencia de riesgo entre el grupo sin dato y el grupo observado evaluado en $x = c$. La imputación solo coloca un valor neutro para que la fila pueda usarse, y la información de la ausencia queda en β_2. Sin la indicadora, el grupo sin dato quedaría forzado a seguir la misma recta que los observados, lo que sesgaría β_1 hacia cero.

4.3.4. Valores extremos

Topes en el percentil 99. Cómo: A `delinq_2yrs`, `inq_last_6mths`, `open_acc`, `total_acc`, `antig_credito_meses`, `annual_inc` y `revol_bal` se les aplicó $x^* = \min(x, \hat{q}_{0,99})$, con $\hat{q}_{0,99}$ el percentil 99 de entrenamiento. El mismo valor se aplicó a validación y prueba. **Justificación estadística:** Estas variables son conteos o montos con cola derecha pesada. En la regresión logística, la influencia de una observación sobre la estimación por máxima verosimilitud crece con su apalancamiento, y el estimador no es robusto frente a valores extremos de las covariables. Truncar la cola (*winsorización*) acota esa influencia modificando solo cerca del 1 %de las observaciones, con poco sesgo. Se truncó únicamente por arriba porque todas tienen un límite inferior natural en 0. No se truncaron `dti`, `revol_util` ni `emp_length` porque tienen rangos acotados y no presentan colas extremas: en entrenamiento, el percentil 99,9 de `dti` (29,47) es casi igual a su máximo (29,99) (Tabla 9). **Para qué.** Que pocos créditos atípicos no determinen los coeficientes.

`pub_rec`. **Cómo:** Se truncó en 2 (categorías 0, 1 y 2 o más). **Justificación estadística:** Los valores altos son muy raros y, con pocos malos entre ellos, no permiten distinguir un efecto distinto entre 3, 4 o más registros. El corte es una regla fija, con base en el significado sustantivo de la variable. **Para qué.** Evitar que unos pocos casos extremos dominen la estimación.

4.3.5. Transformaciones

Logaritmo de `annual_inc` y `revol_bal`. Cómo: Se aplicó $\log(1 + x)$ después del tope. **Justificación estadística:** Ingreso y saldo son positivos y asimétricos hacia la derecha. En el logit se supone que el efecto de una covariable es lineal. En escala natural, un aumento de 1.000 dólares significaría lo mismo para un ingreso de 20.000 que para uno de 200.000, lo que no es razonable. En escala logarítmica, un cambio de una unidad equivale a un cambio proporcional, que es la forma natural de medir diferencias entre ingresos. Además, el logaritmo estabiliza la varianza y reduce el peso de los valores grandes. Se usó $1 + x$ porque el saldo rotativo toma el valor 0, para el cual el logaritmo no está definido. **Para qué.** Acercar la relación con el logit a una forma lineal y mejorar la estabilidad numérica.

4.3.6. Variables categóricas

`purpose` y `home_ownership`. **Cómo:** Las categorías de `purpose` con frecuencia menor al 1 %en entrenamiento se agruparon como "raras". Cada variable se codificó con indicadoras, omitiendo la categoría más frecuente como base. Las categorías no vistas en entrenamiento se asignan a "raras" (`purpose`) u OTHER (`home_ownership`).

4.3.7. Estandarización

Cómo: Las variables numéricas se transformaron como $z_{ij} = (x_{ij} - \hat{\mu}_j)/\hat{\sigma}_j$, con la media y la desviación estándar de entrenamiento. Las indicadoras y las categóricas no se escalaron. **Justificación estadística:** Primero, la regresión logística se ajustó con penalización L_2 (y L_1 para comparar), que castiga la magnitud de los coeficientes y, por tanto, depende de la escala: una variable medida en dólares tendría coeficientes pequeños y casi no se penalizaría, mientras que una en escala 0–10 se penalizaría mucho más. Estandarizar pone todas las variables en igual condición frente a la penalización. **Para qué:** Que la regularización trate a las variables por igual y que los modelos converjan de forma estable.

4.3.8. Verificaciones

Se comprobó que los créditos de las tres particiones fueran todos a 36 meses, que la antigüedad crediticia no fuera negativa, que la proporción de `nunca_mora` fuera estable entre años, que no quedaran valores nulos, que las tres matrices tuvieran las mismas columnas y el mismo número de filas que su variable objetivo, y que las variables estandarizadas tuvieran media 0 y desviación 1 en entrenamiento. No se encontraron columnas constantes. Tras el preprocesamiento, las matrices tienen 31.505, 14.967 y 28.458 filas (entrenamiento, validación y prueba), con 30 variables explicativas y tasas de clientes malos de 12,29 %, 13,78 %y 13,61 %. Los parámetros, el escalador y las matrices se guardaron para reproducir el análisis.

4.4. Análisis descriptivo

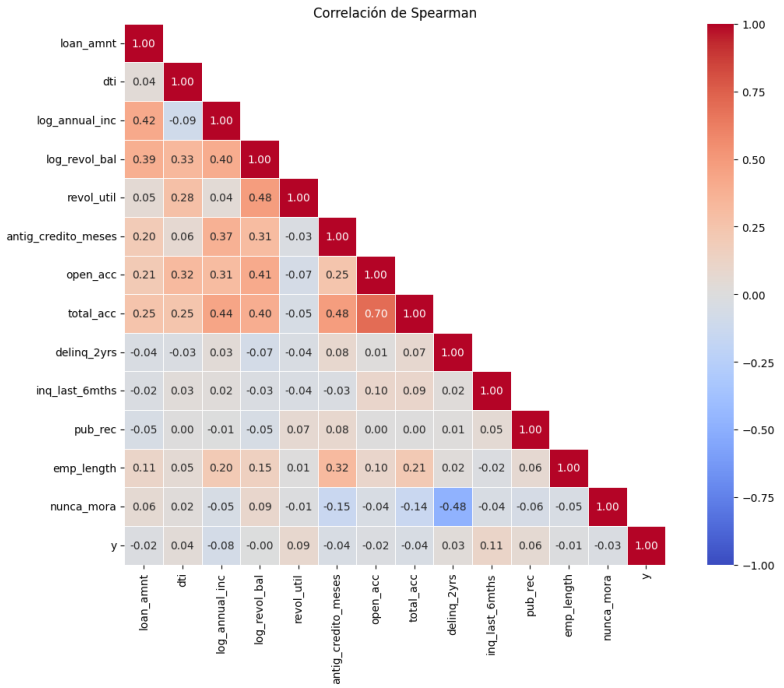
El análisis descriptivo se realizó con el conjunto de entrenamiento ya preprocesado (31.505 créditos, de los cuales 3.873 son malos, es decir, el 12,29 %). Primero se examinan las asociaciones entre variables, luego la distribución de las principales variables numéricas y discretas según la condición de incumplimiento, y finalmente la relación conjunta entre la carga de deuda y la utilización del crédito rotativo.

4.4.1. Asociación entre las variables y el incumplimiento

La Figura 1 presenta las correlaciones de Spearman entre las variables numéricas y el indicador de incumplimiento. Se utilizó la correlación de rangos y no la de Pearson porque varias variables son asimétricas o son conteos con muchos empates, y porque la respuesta es binaria.

Figura 1

Matriz de correlaciones de Spearman entre las variables numéricas



Nota. Las celdas muestran coeficientes ρ de Spearman; la última fila y columna corresponden al indicador de incumplimiento ($y = 1$ para créditos malos).

Las asociaciones individuales con el incumplimiento son débiles: ninguna supera $|\rho| = 0{,}11$ (Figura 1, última fila). Las más altas corresponden al número de consultas en los últimos seis meses (`inq_last_6mths`, $\rho = 0{,}110$), la utilización del crédito rotativo (`revol_util`, 0,085), el ingreso anual (`log_annual_inc`, $-0{,}078$) y el número de registros públicos (`pub_rec`, 0,056), con los signos esperados: más consultas, más utilización y más registros acompañan al incumplimiento, y un mayor ingreso lo acompaña menos. Ninguna variable por sí sola separa bien a los buenos de los malos, lo que anticipa un poder discriminante limitado para cualquier modelo construido con ellas. Conviene recordar que Spearman solo detecta relaciones monótonas, por lo que subestima asociaciones que no lo son, como se verá en las variables discretas.

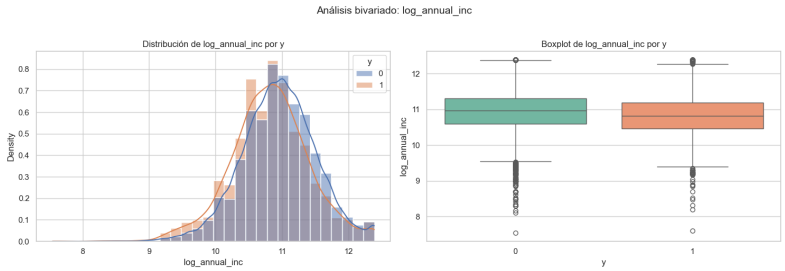
Entre los predictores, la dependencia más alta es la del número de cuentas abiertas (`open_acc`) con el total histórico de cuentas (`total_acc`), con $\rho = 0{,}70$ (Figura 1). Es esperable, pues las cuentas abiertas son un subconjunto de las históricas, y advierte sobre un riesgo de multicolinealidad que inflaría la varianza de los coeficientes de la regresión logística; este riesgo se atenúa con la penalización L2 del modelo de referencia. Las demás asociaciones entre predictores son moderadas (todas inferiores a 0,50 en valor absoluto); la de $-0{,}48$ entre `nunca_mora` y `delinq_2yrs` es estructural, pues quien tuvo una mora reciente no puede pertenecer al grupo sin mora registrada.

4.4.2. Variables numéricas

La Figura 2 compara la distribución del logaritmo del ingreso anual entre créditos buenos y malos: el panel izquierdo muestra las densidades y el derecho los diagramas de caja.

Figura 2

Distribución del logaritmo del ingreso anual según la condición de incumplimiento



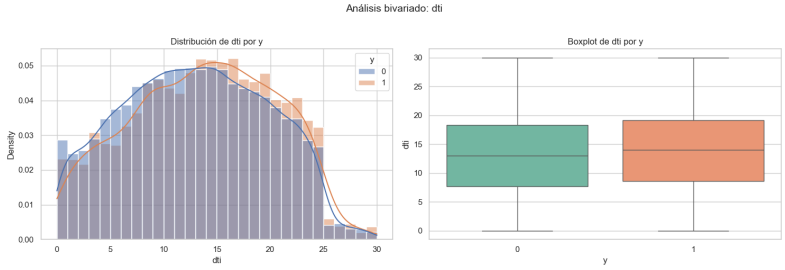
Nota. y = 0 identifica créditos buenos; y = 1, créditos malos. Panel izquierdo: densidades; panel derecho: diagramas de caja.

En el panel izquierdo de la Figura 2 la distribución del ingreso transformado es aproximadamente simétrica en ambos grupos (asimetrías de $-0{,}14$ y $-0{,}09$), lo que respalda el uso del logaritmo para el modelado paramétrico. Las dos curvas se superponen ampliamente, pero la de los clientes que incumplieron ($y = 1$, curva naranja) está desplazada hacia la izquierda respecto a la de los cumplidos ($y = 0$, curva azul). El panel derecho muestra que los malos tienen un menor ingreso a lo largo de toda la distribución: la mediana del ingreso logarítmico es 10,82 para los malos frente a 10,96 para los buenos, y los cuartiles inferior y superior difieren en cerca de 0,13 a 0,14 unidades logarítmicas. En la escala original, la diferencia de medianas equivale a un ingreso mediano de unos 50,000 dólares para los malos frente a unos 57,500 para los buenos, es decir, cerca de 13 % menor.

La Figura 3 compara, de la misma forma, la distribución de la relación deuda-ingreso (`dti`) entre las dos clases.

Figura 3

Distribución de la relación deuda-ingreso según la condición de incumplimiento



Nota. y = 0 identifica créditos buenos; y = 1, créditos malos. Panel izquierdo: densidades; panel derecho: diagramas de caja.

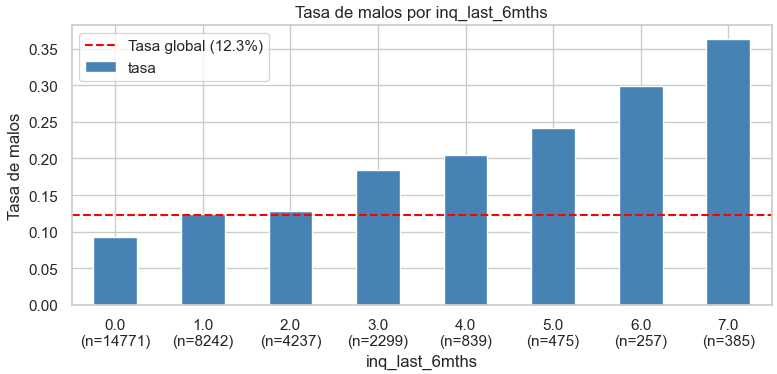
A diferencia de las variables monetarias, en el panel izquierdo de la Figura 3 la distribución de `dti` es prácticamente simétrica en ambos grupos (asimetrías de 0,02 para los buenos y $-0{,}11$ para los malos), con una dispersión casi idéntica (desviación estándar de 6,75) y sin colas extendidas. La diferencia está en la ubicación y no en la forma: el panel derecho y las medidas de posición muestran que toda la distribución de los malos está desplazada entre 0,8 y 1,0 puntos hacia la derecha (mediana de 14,00 frente a 12,97). El tamaño de la diferencia es pequeño ($d = 0{,}11$). Al agrupar `dti` en cuartiles, la tasa de malos aumenta de 10,6 % en el cuartil inferior a 13,8 % en el superior, un incremento más marcado en los primeros tramos que en el último, donde se aplana.

4.4.3. Variables discretas

La Figura 4 muestra la tasa de malos según el número de consultas de crédito en los últimos seis meses.

Figura 4

Tasa de malos según el número de consultas de crédito en los últimos seis meses



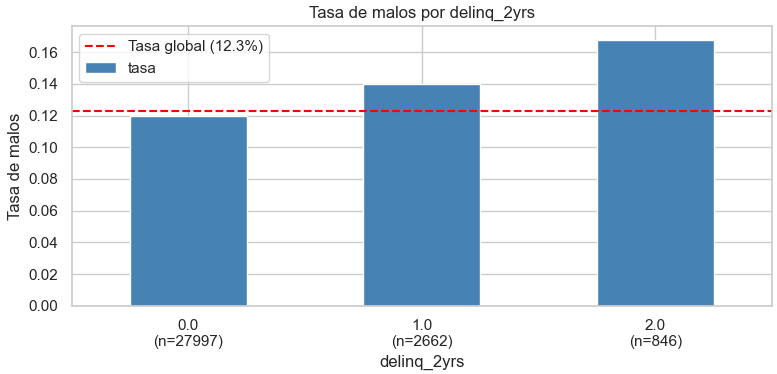
Nota. La línea discontinua indica la tasa global de malos (12,3 %); los tamaños de muestra aparecen bajo cada barra.

Como se observa en la Figura 4, los clientes sin consultas recientes (el 46,9 % de la muestra) tienen la tasa de malos más baja, 9,3 %, por debajo de la línea discontinua que marca la tasa global de 12,3 %. Con una consulta, la tasa sube 3,2 puntos porcentuales, hasta 12,5 %; con dos se mantiene prácticamente igual (12,8 %); y con tres o más (el 13,5 % de la muestra) salta a 21,8 %, 2,35 veces la tasa del primer grupo.

La Figura 5 presenta la tasa de malos según el número de moras en los últimos dos años.

Figura 5

Tasa de malos según el número de moras en los últimos dos años



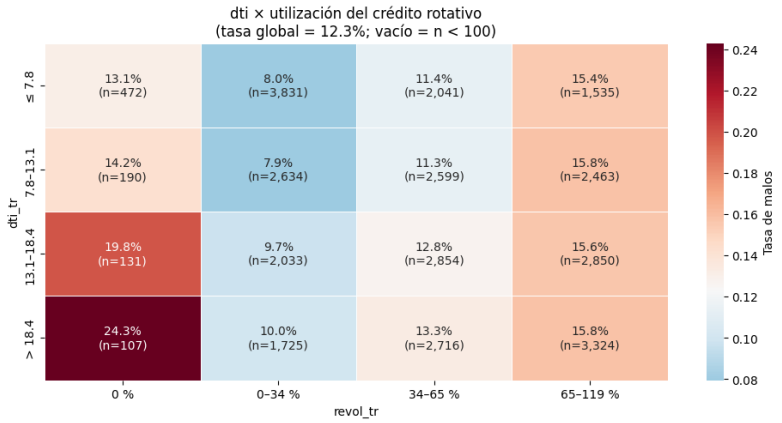
Nota. La línea discontinua indica la tasa global de malos (12,3 %); los tamaños de muestra aparecen bajo cada barra.

Según la Figura 5, el grupo sin moras recientes abarca la gran mayoría de la cartera (n = 27,997, el 88,9 %) y tiene una tasa de malos de 12,0 %, apenas por debajo de la línea de la tasa global (12,3 %), lo que establece la línea base de riesgo para un comportamiento de pago estándar. Con una mora la tasa sube a 14,0 % y con dos a 17,9 %.

4.4.4. Relación conjunta entre la carga de deuda y la utilización del crédito rotativo

Figura 6

Tasa de malos por nivel de endeudamiento y utilización del crédito rotativo



Nota. Cada celda muestra la tasa de malos de la combinación de cuartil de `dti` y tramo de utilización del crédito rotativo.

El análisis bivariado de la Figura 6 muestra tres patrones.

- **Utilización moderada.** Las tasas de malos más bajas de todo el mapa (7,9 % y 8,0 %) se observan en prestatarios con una utilización mayor que 0 % y hasta 34 %, y una carga de deuda baja o media (`dti_tr` $\leq$ 13,1). Es decir, el perfil de menor riesgo no corresponde a quienes no usan su crédito rotativo, sino a quienes lo usan de forma moderada.
- **Utilización alta.** En el extremo derecho del mapa (utilización de 65 % a 119 %), las tasas superan el 15 % y se mantienen en ese nivel con independencia de la relación deuda-ingreso, en línea con la tasa marginal de 15,7 % de este tramo.
- **Utilización nula.** Este grupo tiene una tasa marginal (15,7 %) igual a la del tramo de mayor utilización y casi el doble que la del tramo moderado, de modo que la ausencia de uso del crédito rotativo no se asocia con un menor riesgo. Dentro de este grupo, la tasa llega a 24,3 % cuando `dti_tr` $>$ 18,4, la más alta del mapa. Esta celda debe leerse con cautela: los 900 créditos con utilización nula se reparten entre cuatro cuartiles, por lo que cada celda tiene en promedio unos 225 créditos y un margen de error del orden de ± 6 puntos porcentuales.

4.5. Modelo de referencia

4.5.1. Especificación y selección del hiperparámetro

Como modelo de referencia se ajustó una regresión logística con penalización L2 (*ridge*), que estima la probabilidad de que un crédito sea malo, $P(y = 1 \mid \mathbf{x})$, a partir de las 30 variables preprocesadas. Los coeficientes se obtienen minimizando la pérdida logarítmica regularizada

$$\min_{\beta_0, \boldsymbol{\beta}} \; \frac{1}{2}\|\boldsymbol{\beta}\|_2^2 \; + \; C \sum_{i=1}^{n} \Big[- y_i \log \hat{p}_i - (1 - y_i) \log(1 - \hat{p}_i) \Big], \qquad \hat{p}_i = \frac{1}{1 + e^{-(\beta_0 + \mathbf{x}_i^\top \boldsymbol{\beta})}},$$

donde el intercepto β_0 no se penaliza. El término $\|\boldsymbol{\beta}\|_2^2$ contrae los coeficientes hacia cero sin anularlos, lo que reduce la varianza de las estimaciones cuando los predictores están correlacionados (por ejemplo, el número de cuentas históricas y el de líneas abiertas, con $\rho = 0{,}70$).

Como las variables numéricas se estandarizaron con los parámetros del conjunto de entrenamiento, la penalización actúa sobre una escala comparable para todas ellas. El parámetro C es el inverso de la intensidad de la regularización: valores pequeños implican mayor contracción (más sesgo y menos varianza) y valores grandes se aproximan al ajuste sin penalizar.

El valor de C se eligió con el conjunto de validación, sin utilizar el de prueba, entre trece valores equiespaciados en escala logarítmica, de 10^{-4} a 10^{2} (dos por década). El criterio fue la pérdida logarítmica (*LogLoss*), una regla de puntuación propia que evalúa la calidad de las probabilidades y no solo el orden de los clientes, lo cual es coherente con el objetivo de estimar la probabilidad de incumplimiento. Se fijó una tolerancia de 10^{-4} para considerar equivalentes las configuraciones con desempeño prácticamente igual, entre las cuales se habría escogido la de menor C, es decir, el modelo más regularizado. En la práctica esta regla no fue necesaria: ninguna otra configuración quedó dentro de la tolerancia, pues los valores vecinos ($C = 0{,}00316$ y $C = 0{,}03162$) tuvieron una pérdida de validación de 0,38824, mayor en $3{,}6 \times 10^{-4}$ que la del mínimo. Todas las configuraciones convergieron.

La pérdida de entrenamiento disminuyó de forma monótona al aumentar C, como es esperable al relajar la penalización, mientras que la de validación alcanzó su mínimo en $C = 0{,}01$ (LogLoss de 0,3879) y aumentó ligeramente para valores mayores. Esta forma de U de la pérdida de validación es la señal habitual del compromiso sesgo–varianza: más allá de $C = 0{,}01$ el modelo se ajusta mejor a la muestra de entrenamiento, pero generaliza peor. Por ello se adoptó $C = 0{,}01$, un valor interior de la rejilla, que corresponde a una regularización fuerte.

4.5.2. Métricas de evaluación

Se emplearon métricas de dos tipos. Las de *discriminación* miden si el modelo ordena los créditos de menor a mayor riesgo: el AUC es la probabilidad de que un cliente malo elegido al azar reciba una probabilidad estimada mayor que un cliente bueno; el índice de Gini es $2\,\mathrm{AUC} - 1$; y el estadístico KS es la máxima distancia entre las distribuciones acumuladas de las probabilidades estimadas de buenos y malos. Las de *calidad probabilística* miden si los valores estimados son adecuados como probabilidades: el Brier Score es el error cuadrático medio entre la probabilidad estimada y el resultado observado; el LogLoss es la pérdida logarítmica media; y el Brier Skill Score (BSS) compara el Brier del modelo con el de una predicción nula que asigna a todos los créditos la tasa de malos de entrenamiento (12,29 %), evaluada sobre cada conjunto, $\mathrm{BSS} = 1 - \mathrm{Brier}_{\mathrm{modelo}}/\mathrm{Brier}_{\mathrm{nulo}}$. Finalmente, la *calibración* se evaluó con la probabilidad media estimada frente a la tasa observada y con el intercepto y la pendiente de la regresión logística de y sobre el logit de $\hat{p}$, cuyos valores ideales son 0 y 1. Una pendiente mayor que uno indica probabilidades demasiado concentradas hacia la media, y una menor que uno, probabilidades demasiado extremas.

4.5.3. Resultados en entrenamiento, validación y prueba

La Tabla 11 resume el desempeño del modelo en los tres conjuntos.

Tabla 11
Desempeño de la regresión logística L2 ($C = 0{,}01$) en los conjuntos de entrenamiento, validación y prueba.

Métrica	Entrenamiento	Validación	Prueba
Discriminación			
AUC	0,6808	0,6367	0,6284
Gini	0,3616	0,2734	0,2567
KS	0,2618	0,1954	0,1887
Calidad probabilística			
Brier Score	0,1024	0,1157	0,1151
Brier del modelo nulo[a]	0,1078	0,1190	0,1178
Brier Skill Score	0,0499	0,0285	0,0229
LogLoss	0,3497	0,3879	0,3866
LogLoss del modelo nulo[a]	0,3727	0,4019	0,3986
Calibración			
Tasa observada de malos	12,29 %	13,78 %	13,61 %
Probabilidad media estimada	12,29 %	12,16 %	12,57 %
Intercepto de calibración	—	0,2213	0,0696
Pendiente de calibración	—	1,0385	0,9870

[a] Predicción constante igual a la tasa de malos de entrenamiento (12,29 %), evaluada sobre los resultados observados de cada conjunto.

Entrenamiento y validación. El AUC pasó de 0,6808 a 0,6367 y el KS de 0,2618 a 0,1954, lo que indica una menor separación entre buenos y malos fuera de la muestra de ajuste. El LogLoss aumentó de 0,3497 a 0,3879, pero este aumento no puede atribuirse por completo a una pérdida de capacidad predictiva. La tasa de malos subió de 12,29 % en entrenamiento a 13,78 % en validación, y esto encarece el LogLoss incluso para la predicción nula, cuyo valor pasa de 0,3727 a 0,4019 (un aumento de 0,029, que equivale a cerca de tres cuartas partes del aumento de 0,038 del modelo). Medido contra esa referencia, el modelo mejora el LogLoss en 0,023 en entrenamiento (6,2 %) y en 0,014 en validación (3,5 %). El BSS, que se mantiene positivo, muestra el mismo patrón (0,0499 y 0,0285). En consecuencia, la diferencia entre ambos conjuntos combina el optimismo propio de evaluar un modelo sobre los datos con que se ajustó con el cambio temporal de la población. Un cambio en la tasa base no modifica por sí solo el AUC, que depende únicamente del orden de las probabilidades; por ello la caída de 0,044 en esta métrica sí refleja una menor discriminación fuera de muestra, aunque no puede atribuirse exclusivamente al sobreajuste, pues también puede deberse a cambios en la composición de los clientes o en su relación con el incumplimiento.

Prueba. En el conjunto de prueba, que no intervino en ninguna decisión de ajuste, el modelo obtuvo un AUC de 0,6284, un Gini de 0,2567 y un KS de 0,1887. Es decir, ante un cliente malo y uno bueno elegidos al azar, el modelo asigna mayor probabilidad al malo en el 62,8 % de los casos. La curva ROC (Figura 7, izquierda) se ubica por encima de la diagonal, pero con una separación moderada, coherente con el AUC y el KS reportados. Se trata, por tanto, de una capacidad de discriminación superior al azar, pero limitada. El Brier Score (0,1151) y el LogLoss (0,3866) son prácticamente iguales a los de validación, y el BSS (0,0229) indica una mejora de 3,0 % en LogLoss y 2,3 % en Brier frente a la predicción nula. Las métricas de validación y de prueba son cercanas (el AUC difiere en 0,008), lo que sugiere un desempeño estable en los dos semestres posteriores al entrenamiento; la prueba, al no haberse empleado en la elección de C, es la estimación no sesgada del desempeño fuera de muestra.

Calibración. La probabilidad media estimada subestimó la tasa observada en ambos conjuntos: 12,16 % frente a 13,78 % en validación (1,6 puntos porcentuales) y 12,57 % frente a 13,61 % en prueba (1,0 puntos). El sentido es el mismo porque el modelo está anclado a la tasa de entrenamiento, menor que la de los semestres posteriores. La pendiente de calibración fue 1,0385 en validación y 0,9870 en prueba, es decir, cercana a uno; que en validación sea algo mayor que uno es coherente con la fuerte regularización elegida, que contrae ligeramente las probabilidades hacia la media. El intercepto bajó de 0,2213 a 0,0696, de modo que en prueba el nivel de las probabilidades queda más cerca del observado. La curva de calibración por deciles (Figura 7, centro) muestra que los deciles de menor riesgo y el de mayor riesgo quedan sobre la diagonal, mientras que en los deciles intermedios la tasa observada supera a la estimada, lo que concuerda con la subestimación del nivel medio. Por su parte, las probabilidades estimadas (Figura 7, derecha) se concentran entre aproximadamente 0,05 y 0,25, con asimetría hacia la derecha; esta baja dispersión es coherente con la discriminación limitada del modelo.

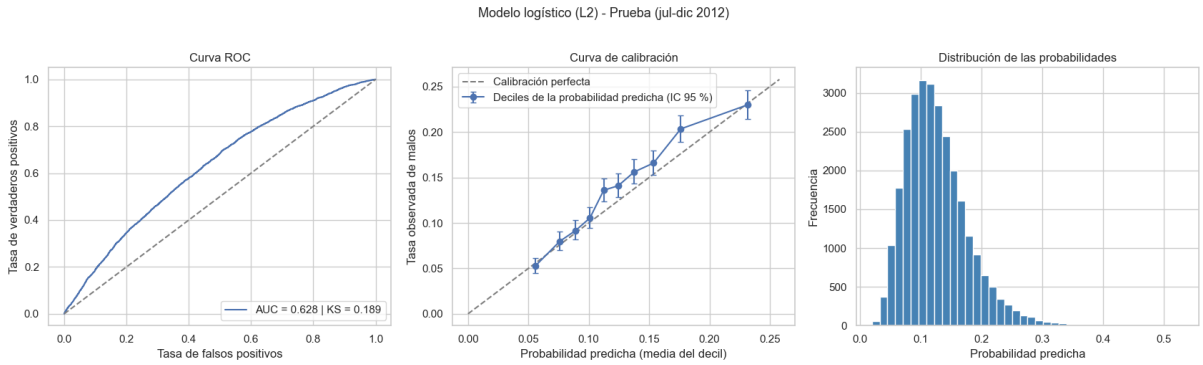


Figura 7
Desempeño de la regresión logística L2 ($C = 0{,}01$) en el conjunto de prueba (jul–dic 2012): curva ROC (izquierda), curva de calibración por deciles de la probabilidad estimada con intervalos de confianza del 95 %(centro) y distribución de las probabilidades estimadas (derecha).

4.5.4. Recalibración del intercepto

Como análisis complementario se estimó, con el conjunto de validación, un desplazamiento del intercepto de 0,1481 (con la pendiente fija en uno, por lo que difiere del intercepto de calibración de 0,2213, que se estima junto con la pendiente), y se aplicó a las probabilidades del conjunto de prueba. Por construcción, el AUC (0,6284), el Gini (0,2567) y el KS (0,1887) no cambian, pues el ajuste modifica el nivel de las probabilidades y no su orden. El Brier pasó de 0,1151 a 0,1150 y el LogLoss de 0,3866 a 0,3863, mejoras marginales; sin embargo, la probabilidad media subió de 12,57 % a 14,24 %, quedando por encima de la tasa observada (13,61 %). El desplazamiento estimado en validación (0,1481) fue mayor que el que requería la prueba, que con la pendiente fija en uno es de 0,0940 (calculado a posteriori y solo con fines diagnósticos), porque la tasa de malos en validación fue algo mayor y se estimó con un solo semestre; la diferencia de 0,054 explica la sobreestimación de 0,6 puntos porcentuales. Dado que la mejora es despreciable y el ajuste no se trasladó bien al periodo siguiente, se conservó el modelo original como modelo de referencia.

4.5.5. Síntesis

El modelo de referencia discrimina mejor que el azar, aunque de forma limitada (AUC de 0,63 en prueba), con un desempeño estable entre validación y prueba y probabilidades razonablemente calibradas, con una subestimación de 1 a 1,6 puntos porcentuales atribuible al aumento de la tasa de malos entre el periodo de entrenamiento y los posteriores. La mejora

empírica sobre la predicción nula es modesta (3 % en LogLoss en prueba) y su significancia estadística no se ha establecido formalmente, lo cual es coherente con el análisis descriptivo, donde ninguna variable por sí sola presentó una asociación fuerte con el incumplimiento. Estos resultados constituyen el punto de comparación para los modelos posteriores.

4.6. Red Neuronal

Se construyó una red de dos capas (64 y 32 neuronas) que recibe los datos de un crédito y devuelve su probabilidad de impago. Sus ajustes se eligieron mediante búsqueda aleatoria: se probaron 40 combinaciones al azar y se seleccionó la que mejor separó a los clientes buenos y malos en un semestre que la red no había analizado previamente.

La idea de la red. La regresión logística asigna a cada variable un peso fijo, suma todo y lo convierte en una probabilidad. La red hace lo mismo, pero antes pasa los datos por capas de ¡¡neuronas¿¿. Cada neurona combina las variables a su manera, lo que le permite detectar combinaciones que la regresión logística no logra ver. Por ejemplo, que un *dti* alto sea más grave cuando el ingreso es bajo.

$$\hat{p} = \sigma\big(W_3\,\mathrm{ReLU}(W_2\,\mathrm{ReLU}(W_1 x + b_1) + b_2) + b_3\big)$$

Si se quitan las capas del medio, queda exactamente la regresión logística. Por eso la logística es la comparación justa: la red es la misma idea con más libertad.

4.6.1. Cómo está hecha

Se programó desde cero en NumPy (`src/red_neuronal.py`), sin librerías de redes, con el fin de poder explicar cada paso. Todos los ajustes se encuentran en `config.ini` y se pueden modificar en vivo con `--set`.

- **Salida:** una sigmoide, que deja el resultado entre 0 y 1. Ese número es la PD (probabilidad de incumplimiento).
- **Qué aprende:** minimiza la entropía cruzada, la misma medida de error de la regresión logística. Castiga severamente predecir «casi seguro paga» a un cliente que finalmente no pagó [1].
- **Pesos iniciales:** se sortean con una varianza ajustada al tamaño de cada capa (He para ReLU, Glorot para tanh). Si inician muy grandes o muy pequeños, la red no aprende [3, 4].
- **Cómo aprende:** calcula cuánto contribuye cada peso al error (retropropagación) y lo corrige de forma gradual. Estos cálculos se comprobaron contra una aproximación numérica.

Datos. Solo créditos a 36 meses, separados por fecha:

Tabla 12
Conjuntos de datos y sus usos

Conjunto	Periodo	Créditos	Para qué se usa
Entrenamiento	jun-2007 a dic-2011	31.505	La red aprende sus pesos
Validación	ene a jun-2012	14.967	Elegir los ajustes y cuándo parar
Prueba	jul a dic-2012	28.458	Nota final, una sola vez

4.6.2. Hiperparámetros

Tabla 13
Ajustes y evaluación del modelo

Ajuste	Qué hace, en sencillo	Probamos	Quedó	Por qué
Capas y neuronas	Cuánta ≪capacidad≫ tiene la red para aprender patrones	De 1 capa de 8 a 3 capas (64-32-16)	64-32	Tuvo el mejor AUC en validación (0,6381). Redes de 16 a 64-32-16 quedaron casi iguales: la capacidad no era lo que limitaba.
Activación	La ≪curva≫ que cada neurona aplica; sin ella, la red sería otra logística	ReLU, tanh	ReLU	Rindieron igual (mediana 0,633 y 0,635); ReLU es más simple y fue la del mejor modelo.
Penalización L2	Multa a los pesos grandes, para que la red no se aprenda de memoria el entrenamiento [1]	0,000001 a 0,01	0,0014	Con 4.097 pesos y 31.505 créditos, la red puede memorizar. Con Adam fue el ajuste más ligado al AUC: dentro del rango probado, más multa se asoció con mejor AUC en validación.
Dropout	Apaga al azar el 30 %de las neuronas en cada paso; la red no puede depender de unas pocas [5]	0 a 0,5	0,3	Otro freno contra memorizar; ningún valor ganó con claridad.
Optimizador	La regla para corregir los pesos con el gradiente [6]	Adam, SGD	Adam	Fue más estable: mediana 0,635 contra 0,626 de SGD. Las 3 peores configuraciones fueron SGD, y Adam no depende tanto de acertar la tasa.
Tasa de aprendizaje	Qué tan grande es cada corrección	Adam 0,0001 a 0,01; SGD 0,001 a 0,1	0,0026	Muy pequeña no aprende a tiempo; muy grande salta y no se estabiliza. Con SGD fue decisiva: por debajo de 0,002 el AUC cayó a 0,55–0,62. Con Adam casi no influyó, porque Adam ajusta el paso por su cuenta.
Tamaño de lote	Cuántos créditos mira la red antes de cada corrección	256, 512, 1024	512	Equilibrio entre rapidez y estabilidad.
Parada temprana	Detiene el entrenamiento cuando deja de mejorar en validación [7]	Fija: paciencia de 10 épocas	Paró en la época 20 y se quedó con la 10	Es el freno más directo: seguir entrenando solo mejoraba el entrenamiento, no la validación.

Nota. AUC = área bajo la curva ROC; SGD = descenso por gradiente estocástico.

En la tabla 13 podemos ver la explicación los hiperparámetros de la red neuronal.

Lo importante. Se utilizaron tres frenos contra la memorización ($L2$, *dropout* y parada temprana) porque la red tiene muchos más pesos que la regresión logística (4097 contra 31). La penalización $L2$ y la tasa de aprendizaje se sortearon en escala logarítmica: lo que importa es su orden de magnitud (0,001 contra 0,01), no el decimal exacto.

4.6.3. Método de búsqueda: búsqueda aleatoria

El método empleado fue la búsqueda aleatoria (*random search*). Se sortearon 40 combinaciones de los siete hiperparámetros, se entrenó una red neuronal con cada una y se eligió la de mayor AUC en el conjunto de validación. También se probaron 5 regresiones logísticas para fines de comparación. Todo el proceso tomó 9,7 minutos (`scripts/parte1_pd/buscar_hiperparametros_pd.py`; resultados disponibles en `reports/busqueda_pd.csv`).

Para cada una de las 40 redes se asignó aleatoriamente un valor por hiperparámetro. Por ejemplo: arquitectura 64-32, ReLU, $L2 = 0{,}0014$, *dropout* de 0,3, optimizador Adam, tasa de

aprendizaje de 0,0026 y tamaño de lote de 512. Posteriormente, se procedió al entrenamiento y se registró su AUC en validación. Finalmente, se seleccionó la mejor configuración; en caso de empate, se priorizó la de menor entropía cruzada.

4.6.4. Por qué una búsqueda aleatoria y no una grilla

- Una grilla prueba todas las combinaciones de una lista fija. Con siete hiperparámetros y solo 3 valores por cada uno, ya representarían $3^7 = 2187$ entrenamientos.
- En la mayoría de los casos, importan pocos ajustes [8]. En este contexto, tuvieron mayor peso la penalización $L2$ y, al emplear SGD, la tasa de aprendizaje. Una grilla repite los mismos 3 valores de cada ajuste importante, mientras que 40 sorteos evalúan 40 valores distintos de cada uno.
- Bergstra y Bengio (2012) demostraron que, con el mismo presupuesto computacional, la búsqueda aleatoria encuentra modelos con un desempeño igual o superior a los obtenidos mediante una grilla [8].

4.6.5. Por qué no emplear métodos más sofisticados (búsqueda bayesiana)

La búsqueda bayesiana ahorra entrenamientos cuando cada uno es computacionalmente costoso. En este caso, cada red tardó entre 1 y 80 segundos (con una mediana de 6 s). Además, las mejores configuraciones obtuvieron resultados prácticamente idénticos (como se detalla más adelante), por lo que realizar una búsqueda más fina no habría alterado las conclusiones.

4.6.6. Por qué evaluar con un semestre posterior

El modelo se utilizará para calificar créditos futuros. Por este motivo, cada red se evaluó con el periodo enero-junio de 2012, el cual es estrictamente posterior al periodo de entrenamiento. Mezclar los datos de diferentes años de forma aleatoria (por ejemplo, mediante *k-fold cross-validation*) habría premiado a las redes que no resisten los cambios poblacionales en los clientes a lo largo del tiempo. El conjunto de prueba (julio-diciembre de 2012) se mantuvo completamente aislado durante la fase de búsqueda de hiperparámetros.

4.6.7. Hallazgos principales

Las 10 mejores redes alcanzaron una AUC comprendida entre 0,6365 y 0,6381. Esta diferencia de 0,0016 es menor a la variación natural que presenta una misma red al ser reentrenada con otra semilla aleatoria ($\pm$0,003); es decir, desde el punto de vista estadístico, se encuentran empatadas. La mejor regresión logística alcanzó una AUC de 0,6351, un valor sumamente cercano. El hecho de que casi cualquier red con parámetros razonables ofrezca un desempeño similar indica anticipadamente que en este conjunto de datos existen pocos patrones no lineales aprovechables.

(Bergstra y Bengio 2012), (Hyndman y Athanasopoulos 2021, sec. 5.10).

4.6.8. Resultado: La red no le gana a la logística

En la prueba (jul-dic 2012), la red logró AUC 0,6251 y la logística de referencia 0,6284. Es poca diferencia, pero a favor de la logística. La referencia es la regresión logística del notebook del equipo (scikit-learn, L2 con C elegido en validación); la red se compara con sus predicciones guardadas en prueba.

Tabla 14
Medidas en prueba

Medida en prueba	Red 64-32	Logística
AUC	0,6251	0,6284
Diferencia de AUC (red – logística), bootstrap pareado de 1.000 réplicas	$-0,0033$ [$-0,0062$; $-0,0004$]	—
Diferencia de Brier, mismo bootstrap	≈ 0 (el intervalo incluye el 0)	—
AUC en 30 semillas (media $\pm$ desv.)	$0,625 \pm 0,003$	$0,629 \pm 0,001$ (réplica en NumPy, ver nota)
Pesos que aprende	4.097	31

Nota. AUC = área bajo la curva ROC; Brier = puntuación de Brier. El intervalo entre corchetes corresponde al intervalo bootstrap pareado de 1.000 réplicas.

Como es visible ver en la tabla 14, salvo la fila de 30 semillas, la columna "Logística" corresponde a la obtenida en el *notebook*. Para repetir la regresión logística empleando distintas semillas, el modelo se reajustó utilizando el código implementado en NumPy como una red neuronal sin capas ocultas: con la semilla 42 se alcanzó una AUC de 0,6296, a una diferencia de 0,001 respecto a la referencia, lo cual confirma la exactitud de la implementación desarrollada desde cero. Esta réplica es la que se emplea finalmente en la aplicación y en la *scorecard*.

4.7. Evaluación

4.7.1. Partición de los datos

Tabla 15
Conjuntos de datos, tasa de malos y sus usos

Conjunto	Originación	Créditos	Tasa de malos	Para qué se usa
Entrenamiento	jun 2007 – dic 2011	31.505	12,3 %	Ajustar los pesos
Validación	ene – jun 2012	14.967	13,8 %	Elegir hiperparámetros (C de la logística; capas, L2, dropout de la red) y la época de parada
Prueba	jul – dic 2012	28.458	13,6 %	Medir el desempeño final, una sola vez

La tabla 15 resume las particiones temporales y los periodos excluidos por censura del desenlace.

4.7.2. Por qué se analizaron únicamente créditos a 36 meses

Un crédito revela su estado definitivo (cumplimiento o incumplimiento) únicamente al finalizar su plazo. Los datos disponibles abarcan hasta el año 2015: un crédito a 36 meses originado en 2012 ya ha concluido, mientras que uno a 60 meses de 2011 aún podría encontrarse activo. Si se combinaran, los créditos recientes de 60 meses podrían clasificarse erróneamente

como "buenos" simplemente porque no ha transcurrido el tiempo suficiente para observar un posible incumplimiento. Al restringir el análisis a los créditos de 36 meses, se garantiza que los tres conjuntos de datos presenten desenlaces completos.

4.7.3. Por qué se excluyó el periodo 2013–2015

La exclusión responde a la misma justificación: los créditos originados en dichos años continuaban vigentes al cierre de la ventana temporal de los datos, por lo que su etiqueta de desempeño no resulta confiable. Por ello, no habían completado el horizonte de observación necesario para determinar su estado final.

(Hastie, Tibshirani y Friedman 2009, cap. 7), (Hyndman y Athanasopoulos 2021, sec. 5.10).

4.7.4. Discriminación: ¿pone a los malos por encima de los buenos?

Discriminar es ordenar bien: dar más PD a quien de verdad no paga. No importa aún si la probabilidad es exacta, solo el orden. Se mide con tres números que miran lo mismo desde ángulos distintos.

En la tabla 16 podemos ver las medidas de evaluación (jul–dic 2012, 28.458 créditos):

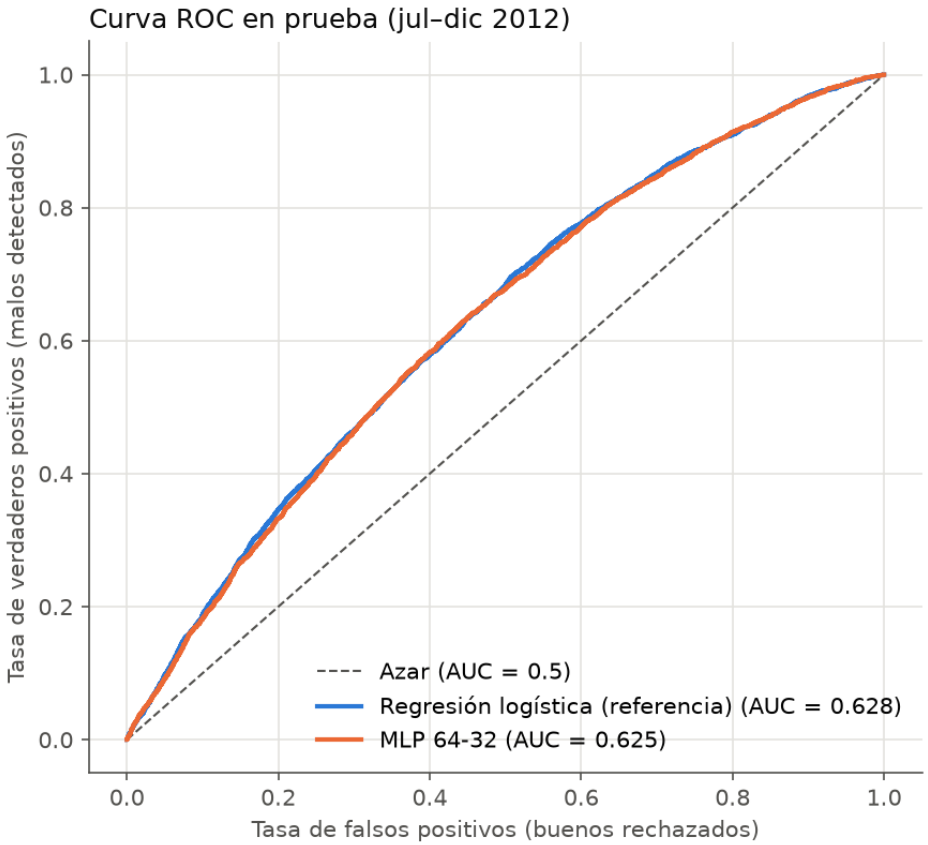
Tabla 16
Medidas de evaluación, preguntas y escalas

Medida	Pregunta que responde	Escala
AUC	Si tomo al azar un crédito malo y uno bueno, ¿con qué probabilidad el modelo le da más PD al malo? [3]	0,5 = lanzar una moneda; 1 = perfecto
Gini $= 2 \cdot \text{AUC} - 1$	Lo mismo, reescalado para que el azar valga 0	0 = azar; 1 = perfecto
KS	¿En qué punto de corte están más separados los malos de los buenos? Es la mayor distancia entre sus distribuciones acumuladas de puntaje [4]	0 = no los separa; 1 = los separa por completo

Las tres medidas cuentan la misma historia: la logística va primero en AUC, en Gini y en KS. Que la red no gane en ninguna, aun con 130 veces más pesos, indica que en estos datos no hay patrones complejos que aprovechar.

La Figura 8 compara la discriminación de la red neuronal y la regresión logística a través de sus curvas ROC.

Figura 8
Curvas ROC de la red neuronal y la regresión logística en prueba

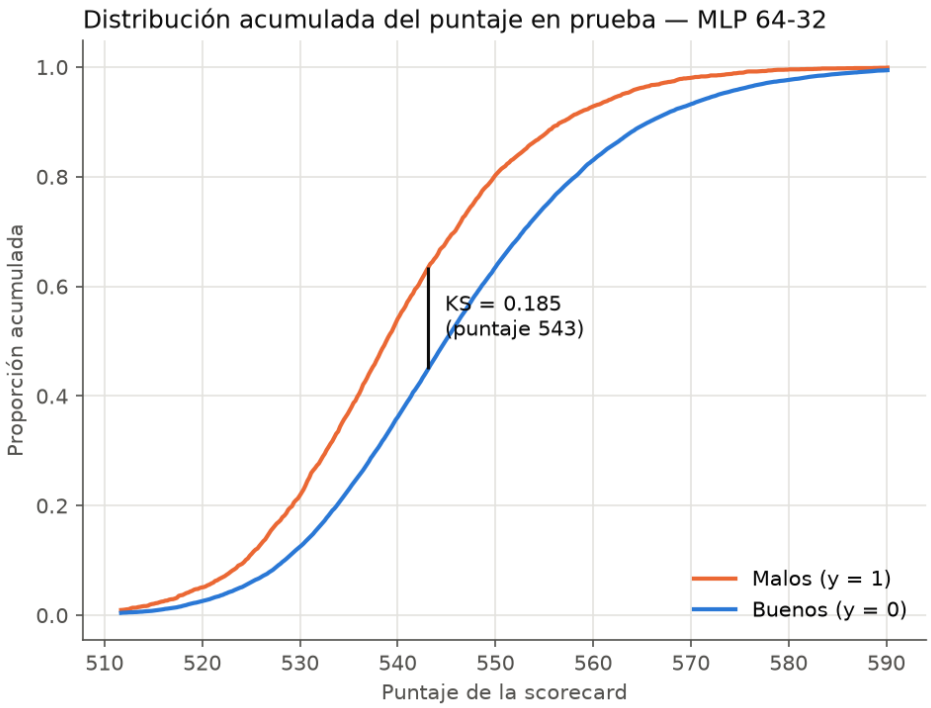


Nota. La línea diagonal representa el desempeño esperado al clasificar al azar.

La curva ROC muestra la tasa de verdaderos positivos frente a la tasa de falsos positivos para distintos umbrales. Como se observa en la Figura 8, ambas curvas casi se superponen en todo el rango; sus AUC en prueba son 0,625 para la red y 0,628 para la logística. Al bajar el umbral aumenta la detección de créditos malos, pero también la tasa de falsos positivos.

La Figura 9 compara las distribuciones acumuladas del puntaje para los créditos buenos y malos.

Figura 9
Distribución acumulada del puntaje según la condición de incumplimiento en prueba



Nota. KS = estadístico de Kolmogórov-Smirnov; la separación máxima observada es 0,185 en el puntaje 543.

Como muestra la Figura 8, la distribución acumulada de los créditos malos queda por encima de la de los buenos en la zona central del puntaje. La separación máxima es 0,185 (18,5 puntos porcentuales) en el puntaje 543; pese a esa diferencia, ambas distribuciones se solapan ampliamente.

4.7.5. Calibración

Tabla 17
Comparación del rendimiento de los modelos

Modelo	Brier	Mejora modelo (BSS)	PD media predicha	Tasa real de malos
Modelo tonto (12,3 %para todos)	0,1178	0 %	12,3 %	13,6 %
Regresión logística (referencia)	0,1151	2,3 %	12,6 %	13,6 %
Red neuronal MLP 64-32	0,1151	2,3 %	12,7 %	13,6 %

Como punto de comparación usamos un modelo sin información (sin información), que asigna a todos los créditos la misma PD: la tasa de malos de entrenamiento (12,3 %). Sirve como referencia porque el Brier por sí solo no dice si un modelo es bueno; lo útil es ver cuánto lo reduce frente a no saber nada del solicitante.

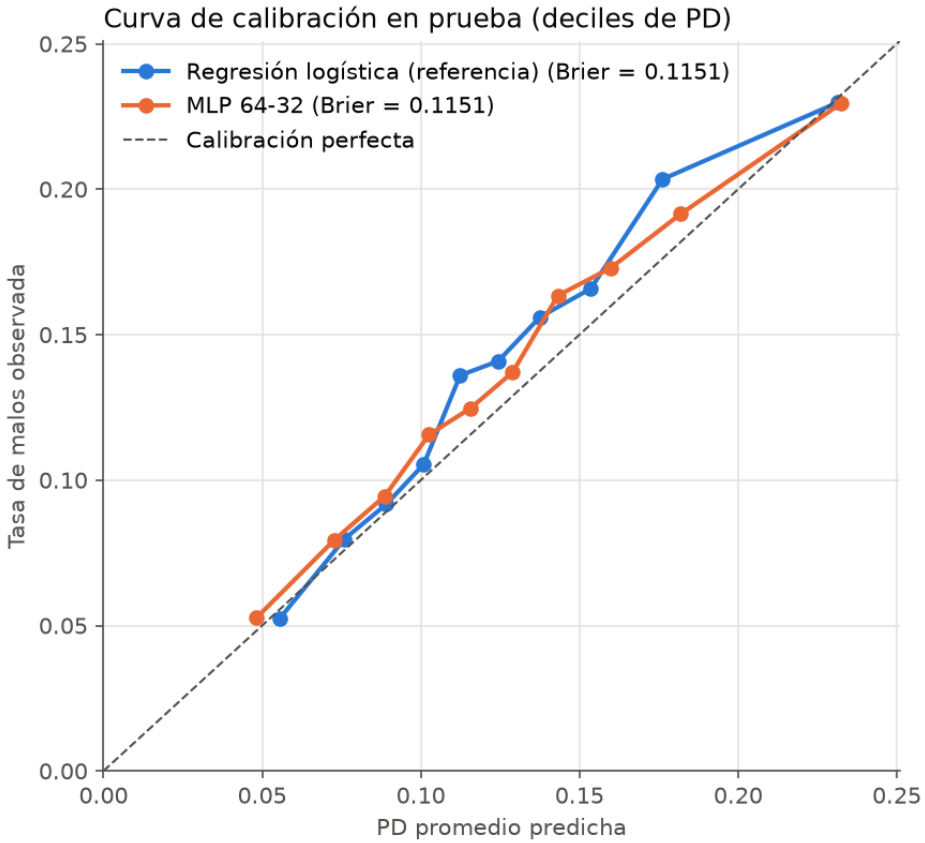
Cómo podemos observar en la tabla 17, el puntaje de Brier, el error cuadrático medio entre la PD predicha y el desenlace observado (1 si el crédito fue malo, 0 si fue bueno), es 0,1151 tanto para la logística como para la red, frente a 0,1178 del modelo sin información que asigna

a todos la tasa de malos de entrenamiento (12,3 %); esto equivale a una mejora relativa de 2,3 %(Brier Skill Score)

La mejora es pequeña, como es habitual en riesgo de crédito, porque el desenlace de cada crédito es binario y conserva un ruido que ningún modelo puede eliminar.

Figura 10

Curva de calibración de la regresión logística en prueba



Nota. KS = estadístico de Kolmogórov-Smirnov; la separación máxima observada es 0,185 en el puntaje 543.

Como se observa en la Figura 10, la curva de calibración sigue de cerca la diagonal de 45° (pendiente 0,99), lo que indica probabilidades bien calibradas en forma; los puntos quedan ligeramente por encima de la recta, pues el modelo predice una PD media de 12,6 %frente a una tasa observada de 13,6 %, reflejo del aumento del riesgo en 2012 respecto al periodo de entrenamiento.

4.7.6. Conclusión

• Partición. Entrenamos con créditos de 2007–2011, elegimos hiperparámetros con el primer semestre de 2012 y evaluamos una sola vez con el segundo semestre de 2012, imitando el uso real del modelo.

• Discriminación. La logística ordena correctamente el 63 %de las parejas malo–bueno (AUC 0,628; Gini 0,257; KS 0,189); la red queda levemente por debajo (AUC 0,625) y la diferencia es significativa.

• Calibración. Las PD siguen la diagonal de 45° (pendiente 0,99) y reducen el Brier en 2,3 %frente al modelo sin información, aunque subestiman la tasa de malos de 2012 (12,6 %frente

a 13,6 %); un ajuste del intercepto lo corrige.

• Efecto del tiempo. El AUC baja de 0,637 en validación a 0,628 en prueba y la tasa de malos sube: el modelo envejece, algo que una partición aleatoria habría ocultado.

• Decisión. Preferimos la logística: iguala o supera a la red con 31 parámetros en lugar de 4.097.

4.8. Scorecard

Una scorecard expresa la PD como un puntaje, donde más puntos significan menos riesgo; como la transformación es monótona, conserva el orden de los clientes y, por tanto, la discriminación del modelo

La escala se fija con tres números, elegidos por convención. Cambiarlos mueve o estira la escala, pero no cambia el orden de los clientes

Tabla 18
Parámetros de escalamiento del puntaje

Parámetro	Nuestro valor	Qué significa
Odds de referencia	50:1	50 buenos por cada malo, o sea PD $=$ $1/51 \approx 2\,\%$
Puntaje base	600	El puntaje que recibe quien tiene esas odds
PDO (puntos para duplicar las odds)	20	Cada 20 puntos más, el riesgo relativo se reduce a la mitad

En la tabla 18 podemos ver los parámeros de escalamiento para el puntaje.

Fijamos un puntaje base de 600 para odds buenos:malos de 50:1 (PD $\approx$ 2 %) y un PDO de 20, de modo que cada 20 puntos adicionales duplican las odds de ser buen pagador.

El PDO (points to double the odds) es el número de puntos necesarios para duplicar las odds de ser buen pagador. Los parámetros de la escala (puntaje base 600, odds de referencia 50:1 y PDO 20) se tomaron de la convención habitual en la industria (Siddiqi 2006); son una elección de escala y no afectan el orden de los clientes ni, por tanto, la discriminación del modelo.

4.8.1. De probabilidad a puntaje

El puntaje es una recta en el logaritmo de las odds: puntaje = A + B · ln(odds). Los tres parámetros fijan los dos números A y B.

Derivación en tres pasos:

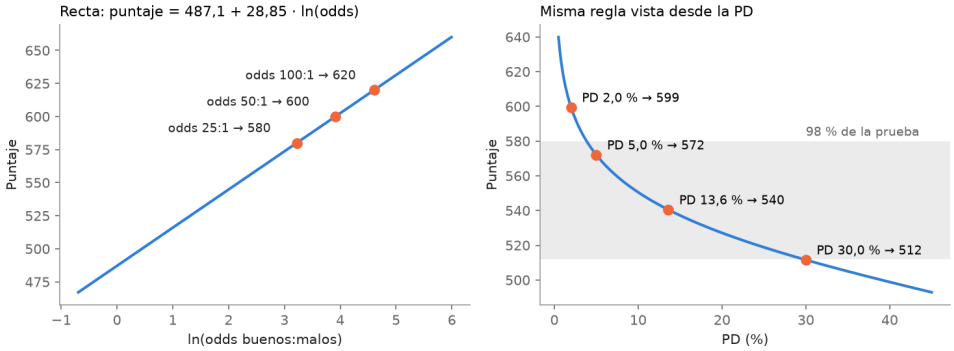
1. Dos condiciones. Con odds 50 el puntaje vale 600: 600 = A + B · ln(50). Con odds 100 (el doble) vale 620: 620 = A + B · ln(100).

2. Restar las dos: $20 = B[\ln(100) - \ln(50)] = B\ln(2)$, así que $B = \text{PDO}/\ln 2 = 20/0{,}693 = 28{,}85$.

3. Despejar A: $A = 600 - 28{,}85\ln(50) = 600 - 112{,}88$, así que $A = 487{,}12$.

Resultado: puntaje $= 487{,}12 + 28{,}85\ln[(1-\text{PD})/\text{PD}]$.

Figura 11
De probabilidad a puntaje



Como se observa en la Figura 11, a la izquierda la regla es una recta: cada vez que las odds se duplican, el puntaje sube 20. A la derecha, la misma regla vista desde la PD es una curva: bajar la PD de 30 %a 13,6 %da 28 puntos, y de 5 %a 2 %da otros 27. La franja gris muestra que casi todos nuestros clientes caen entre 512 y 580 puntos, porque las PD del modelo van de 5 %a 25 %.

4.8.2. Cómo salen los puntos del modelo

Como la regresión logística es lineal en el logit, el puntaje se descompone de forma exacta como la suma de un puntaje base, el del solicitante promedio de entrenamiento (547,5), y los puntos de cada variable, $-B\beta_j(x_j - \bar{x}_j)$. Usamos las variables continuas, de modo que los puntos varían en proporción al valor de cada variable. En la tabla 19 podemos ver el puntaje y lectura por variable.

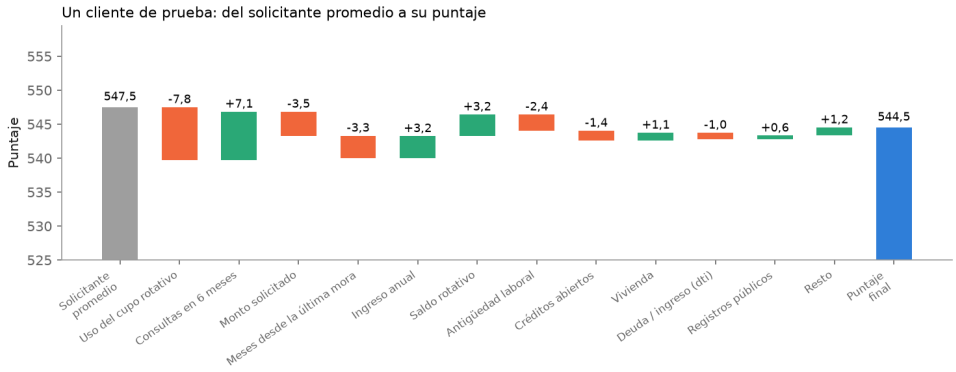
Tabla 19
Puntaje y lectura por variable

Variable	Puntos	Lectura
Uso del cupo rotativo	$-3,8$ por cada 10 puntos porcentuales	Usar más cupo, más riesgo
Consultas en 6 meses	$-6,7$ por consulta	Buscar crédito con urgencia es mala señal
Ingreso anual	$+10,1$ cada vez que se duplica	Más ingreso, menos riesgo
Registros públicos	$-10,0$ por registro	Quiebras o embargos
Moras en 2 años	$-2,9$ por mora	
Monto solicitado	$-0,65$ por cada USD 1.000	
Créditos abiertos	$-0,78$ por crédito	
Total de créditos	$+0,21$ por crédito	Historial más largo
Deuda / ingreso (dti)	$-0,16$ por punto	Efecto pequeño una vez se conoce el ingreso
Antigüedad laboral	$-0,51$ por año; $-12,7$ si no la reportó	No reportar resta mucho
Saldo rotativo	$+1,4$ cada vez que se duplica	
Antigüedad crediticia	$+0,22$ por año	
Nunca ha estado en mora	$+6,2$	Sin mora previa

4.8.3. Ejemplo

Como ejemplo, se presenta un cliente real de prueba: pide USD 15.000 para consolidar deudas, gana USD 70.000 al año, tiene hipoteca, 10 años en su empleo, ninguna consulta reciente y usa el 68,6 %de su cupo rotativo. El modelo le asigna una PD de 12,0 %, equivalente a 544,5 puntos. La Figura 12 muestra el comportamiento de sus variables.

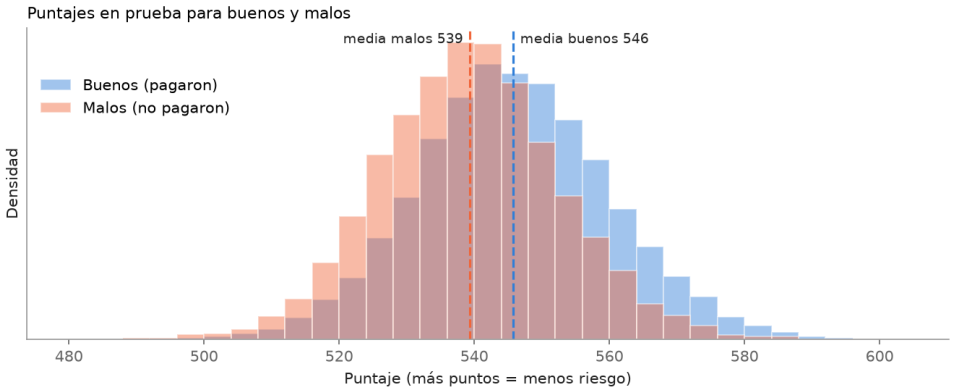
Figura 12
Comportamiento de las variables para el cliente de ejemplo



Parte de 547,5, el solicitante promedio. Usar el 69 %del cupo le resta 7,8 puntos, pero no haber pedido crédito en 6 meses le suma 7,1. El monto alto y una mora vieja restan; el ingreso

y el saldo rotativo suman. Al final queda 3 puntos por debajo del promedio. Así se le puede explicar a cualquier cliente por qué sacó su puntaje.

Figura 13
Distribución de puntajes para créditos buenos y malos



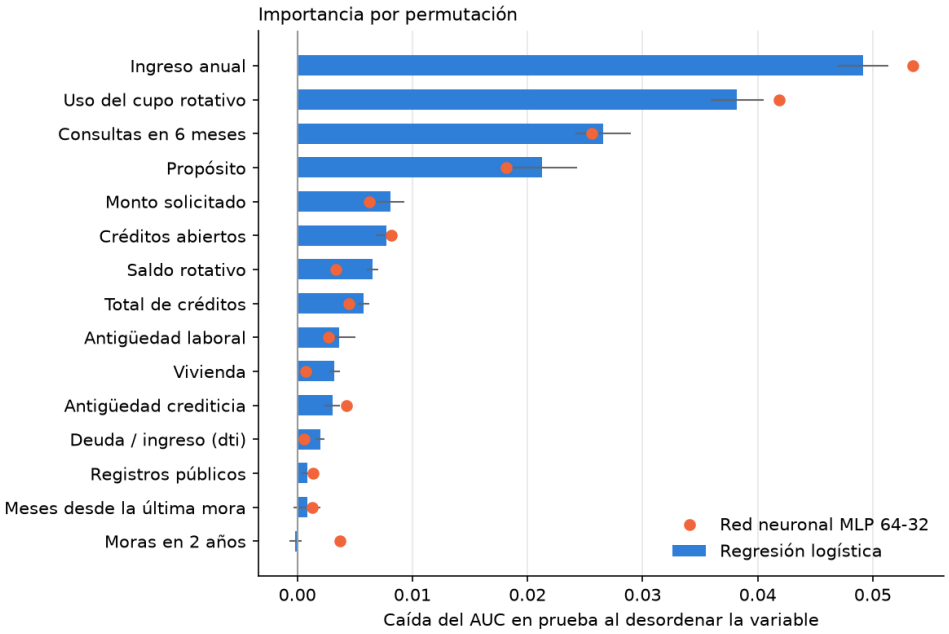
Como se observa en la Figura 13, los malos están corridos a la izquierda: su puntaje medio es 539, frente a 546 de los buenos. Pero las dos campanas se traslapan mucho, que es otra forma de ver el AUC de 0,63: el puntaje ordena bien en promedio, no caso por caso.

4.9. Variables de riesgo

Para identificar las variables de riesgo usamos la importancia por permutación en el conjunto de prueba: se desordena al azar una variable, rompiendo su relación con el incumplimiento, y se mide la caída del AUC; cuanto mayor es la caída, más depende el modelo de esa variable . La dirección de cada efecto se lee en los coeficientes de la regresión logística y en curvas de dependencia parcial.

4.9.1. Qué variables pesan más

Figura 14
Comparación de cambios del AUC al desordenar cada variable



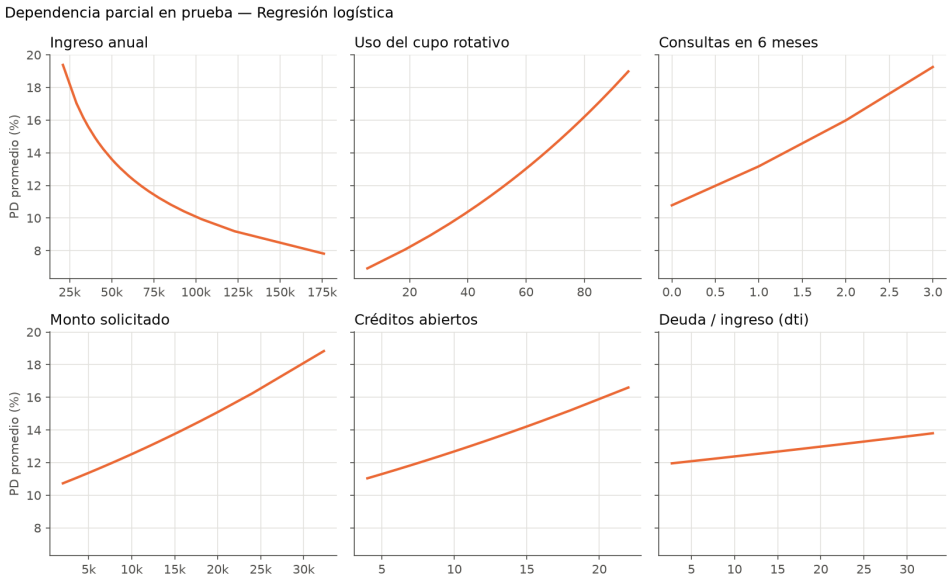
A partir de la Figura 14, las variables más importantes son el ingreso anual, el uso del cupo rotativo, las consultas de crédito en los últimos 6 meses y el propósito del préstamo, que concentran cerca del 75 %de la importancia total; al desordenar el ingreso, el AUC en prueba cae de 0,630 a 0,581. La red neuronal identifica las mismas cuatro variables en el mismo orden, lo que indica que el resultado no depende del modelo

4.9.2. Qúe hace más riesgosa a una persona

Según los coeficientes de la regresión logística, el riesgo aumenta con el uso del cupo rotativo (+14 %en las odds de incumplimiento por cada 10 puntos porcentuales), las consultas recientes (+26 %por consulta) y los préstamos para pequeños negocios (odds 2,2 veces mayores que para consolidar deudas), y disminuye con el ingreso (-30 % cuando se duplica). La persona más riesgosa tiene ingreso bajo, tarjetas casi al tope, varias solicitudes de crédito recientes y pide dinero para un pequeño negocio.

4.9.3. Cómo cambia el riesgo con cada variable

Figura 15
Dependencia parcial de las variables más importantes y el dti



En la Figura 15 se muestran las curvas de dependencia parcial de las cinco variables numéricas más importantes y del dti; las demás tienen una importancia por permutación menor a 0,007 y curvas prácticamente planas. Las curvas de dependencia parcial muestran que la PD promedio baja de 19,4 %a 7,8 %cuando el ingreso pasa de USD 21.000 a 176.000, con rendimientos decrecientes, y sube de forma continua con el uso del cupo rotativo (de 6,9 %a 19,0 %), las consultas recientes y el monto solicitado; el dti apenas la modifica. La red neuronal produce curvas casi idénticas, lo que sugiere que no hay no linealidades relevantes que la logística pierda

4.9.4. Nota

Estos resultados describen asociaciones y no relaciones causales: por ejemplo, las consultas recientes probablemente reflejan una necesidad de financiación que precede al incumplimiento, no su causa. Además, cuando varias variables están correlacionadas, como el ingreso y el dti, la importancia por permutación se reparte entre ellas y puede subestimar a alguna.

Una persona es más riesgosa cuando tiene ingresos bajos, usa la mayor parte de su cupo rotativo, ha hecho varias solicitudes de crédito en los últimos seis meses y pide el préstamo para un pequeño negocio. Estas cuatro variables concentran cerca del 75 %de la importancia por permutación, y la regresión logística y la red neuronal coinciden tanto en el orden de las variables como en la forma de sus efectos.

4.10. Verificación de las pruebas de hipótesis

En el análisis descriptivo se plantearon cinco hipótesis sobre la relación entre las características de los solicitantes y la probabilidad de incumplimiento: consultas recientes, ingreso anual, uso del crédito rotativo, antigüedad del historial crediticio y endeudamiento (DTI). Para revisarlas, se contrastaron las tasas observadas en el conjunto de entrenamiento (créditos a 36 meses originados hasta diciembre de 2011, con una tasa global de malos de 12,29 %) con los resultados del modelo. De la regresión logística se usaron los *odds ratios* (OR) por desviación

estándar y, de la red neuronal, la importancia por permutación y las curvas de dependencia parcial. Además, se calculó el *Information Value* (IV), una medida univariada de la capacidad de una variable para separar buenos y malos pagadores; como referencia habitual, un IV menor de 0,02 indica poca capacidad de separación y entre 0,02 y 0,1 se considera débil. Estas herramientas describen el comportamiento del modelo y no establecen relaciones causales.

Hipótesis 1. A mayor número de consultas crediticias en los últimos seis meses, mayor probabilidad de incumplimiento.

La tasa de incumplimiento aumenta de 9,30 %en los solicitantes sin consultas a 12,46 %con una consulta, 12,84 %con dos y 21,83 %con tres o más. Esta es la variable con mayor IV entre las analizadas (0,124). En la regresión logística el OR es 1,39 por desviación estándar ($p < 0{,}001$). En la red neuronal, la caída media del AUC al permutarla es cercana a 0,0256 y su curva de dependencia parcial es creciente. Por tanto, la hipótesis está **respaldada**.

Hipótesis 2. A menor ingreso anual, mayor probabilidad de incumplimiento, tanto en términos marginales como al controlar por las demás variables.

Por deciles, la tasa baja de 17,83 %en el grupo de menor ingreso a 8,39 %en el noveno decil; en el decil más alto hay un leve repunte (9,98 %) que no altera la tendencia general decreciente. Al controlar por las demás variables el efecto se mantiene: el OR del logaritmo del ingreso es 0,75 por desviación estándar ($p < 0{,}001$). En la red neuronal, el ingreso anual es la variable con mayor importancia por permutación (caída media del AUC cercana a 0,0535) y la probabilidad estimada disminuye, en promedio, al aumentar el ingreso. La hipótesis está **respaldada**.

Hipótesis 3. A mayor utilización del crédito rotativo, mayor probabilidad de incumplimiento entre quienes usan este tipo de crédito.

Entre los solicitantes con utilización mayor que cero, la tasa de incumplimiento pasa de 7,43 %en el decil de menor utilización a 18,45 %en el de mayor. El OR en la regresión logística es 1,49 por desviación estándar ($p < 0{,}001$) y el IV es 0,079. En la red neuronal, la caída media del AUC es cercana a 0,0419 y la dependencia parcial es creciente. Los 900 créditos con utilización de 0 %presentan una tasa de 15,67 %, razón por la cual la hipótesis se acota a quienes usan crédito rotativo. La hipótesis está **respaldada**.

Hipótesis 4. A mayor antigüedad del historial crediticio, menor probabilidad de incumplimiento.

La tasa baja de 16,99 %en el decil de historiales más cortos (hasta 67 meses) a 9,83 %en el de más largos (más de 269 meses). Entre los deciles intermedios las diferencias son pequeñas y no del todo monótonas (entre 11,3 %y 13,3 %), por lo que la diferencia marginal se concentra en los historiales más cortos. Al controlar por las demás variables el signo se mantiene: OR de 0,94 por desviación estándar ($p = 0{,}005$). El IV es 0,026 y la caída media del AUC en la red neuronal es cercana a 0,0043. La hipótesis está **respaldada, con efecto modesto**.

Hipótesis 5. A mayor relación deuda-ingreso (DTI), mayor probabilidad de incumplimiento.

En los deciles, la tasa pasa de 11,06 %en el grupo de menor DTI a 14,38 %en el de mayor DTI, un aumento de unos 3,3 puntos porcentuales con algunas irregularidades intermedias (por ejemplo, 10,30 %en el segundo decil). Al controlar por las demás variables, el efecto es débil: OR de 1,04 por desviación estándar ($p = 0{,}057$). El IV es 0,014 y el DTI tiene la menor importancia por permutación entre las variables de la red (caída media del AUC cercana a 0,0006); su dependencia parcial es relativamente plana. La hipótesis se considera **parcialmente respaldada**: la dirección coincide con lo propuesto, pero el salto descriptivo es moderado y el efecto condicional es débil.

En conjunto, cuatro de las cinco hipótesis quedan respaldadas. Las de consultas recientes, uso del crédito rotativo e ingreso anual tienen la evidencia más sólida, pues coinciden las tasas descriptivas, el IV, los OR y el comportamiento de la red neuronal. La de antigüedad del historial se respalda con un efecto más modesto. El orden por IV (consultas, uso del cupo, ingreso, antigüedad del historial y DTI) es coherente con el orden de importancia por permutación

de la red. El DTI recibe apoyo parcial y es la variable de menor aporte entre las cinco. Estas conclusiones describen asociaciones en la población y el periodo analizados; no indican que modificar una característica del solicitante produzca por sí mismo un cambio en la probabilidad de incumplimiento.

4.11. Discusión y regla de comparación justa

Para una comparación justa, la regresión logística y la red usan los mismos datos, preprocesamiento y particiones; ambas se ajustan con validación (5 y 40 configuraciones) y la diferencia en prueba se evalúa con 30 semillas y un bootstrap pareado

4.11.1. ¿Qué aportó la red frente a la logística?

Respuesta corta: nada en desempeño, y costó más. Vamos por los cuatro criterios.

Tabla 20
Comparación de métricas entre modelos

Métrica	Logística	Red MLP 64-32	Mejor
AUC	0,629	0,625	Logística
Gini	0,258	0,251	Logística
KS	0,189	0,187	Empate
Brier	0,1150	0,1151	Empate

Como se observa en la Tabla 20, en prueba la red no supera a la regresión logística: su AUC es 0,003 menor (IC del 95%: $[-0{,}006; -0{,}0004]$) y su Brier es igual.

4.11.2. variabilidad entre semillas

La logística de esta comparación no es la del notebook (sklearn), sino una equivalente entrenada con nuestro código en NumPy, con la que se pueden variar las semillas; sus resultados en prueba son prácticamente iguales (AUC 0,630 frente a 0,628; Brier 0,1150 frente a 0,1151).

Tabla 21
AUC en prueba con 30 semillas

AUC en prueba (30 semillas)	Logística	Red
Desviación estándar	0,0007	0,0031
Peor	0,627	0,618
Mejor	0,630	0,633

Como es visible en la tabla 21, la red es cuatro veces más sensible a la semilla (desviación del AUC 0,0031 frente a 0,0007); una sola corrida no basta para compararlas.

4.11.3. Costo computacional

Como puede observarse en la tabla 22 la red usa 130 veces más parámetros y 25 veces más tiempo de búsqueda para un desempeño igual o peor.

Tabla 22
Comparativa de complejidad y tiempos de cómputo

	Logística	Red	Razón
Parámetros	31	4.097	$\approx 130\times$
Búsqueda de hiperparámetros	5 configuraciones, 22 s	40 configuraciones, 559 s	$\approx 25\times$
Un entrenamiento final	1,7 s	5,5 s	$\approx 3\times$

4.11.4. Interpratibilidad

Tabla 23
Comparación de interpretabilidad entre regresión logística y red neuronal

	Logística	Red
Efecto de cada variable	Directo: un coeficiente = un odds ratio.	Indirecto: hay que estimarlo con permutación y dependencia parcial.
Scorecard	Exacta: los puntos suman el puntaje sin residuo.	Aproximada: queda un residuo de interacción.
¿Qué variables importan?	Ingreso, uso del cupo, consultas, propósito.	Las mismas cuatro, en el mismo orden.

Al ver la tabla 23 ambos modelos señalan las mismas variables de riesgo con el mismo sentido, pero solo la logística lo hace de forma directa y auditable

4.11.5. Resultado Final

La red neuronal no aportó capacidad predictiva frente a la regresión logística: igual calibración, AUC ligeramente menor, cuatro veces más variabilidad, 130 veces más parámetros y menos interpretabilidad. Por parsimonia, el modelo recomendado es la regresión logística. Lo que sí aportó la red fue evidencia: al no encontrar nada que la logística no viera, confirma que el riesgo en estos datos es esencialmente aditivo.

4.11.6. Aprendizajes

- Una red con 4.097 parámetros no encontró interacciones que la logística no capturara.
- El dti casi no importa aquí. Es una variable clásica de crédito, pero su importancia es de 0,002; su efecto ya lo recogen el ingreso y el uso del cupo.

5. Punto 2

5.1. Fundamentación metodológica del punto 2

5.1.1. Problema de estimación

La pérdida dado el incumplimiento, o LGD (*Loss Given Default*), representa la severidad de pérdida condicionada a que un crédito incumpla. A diferencia de la probabilidad de incumplimiento (PD), la LGD describe cuánto se pierde cuando ocurre dicho evento.

El objetivo predictivo es estimar la severidad esperada a partir de características del crédito disponibles en el momento definido para la decisión:

$$m(\mathbf{x}) = \mathbb{E}\left[LGD \mid D = 1, \mathbf{X} = \mathbf{x}\right],$$

donde $D = 1$ indica incumplimiento y $\mathbf{X}$ representa las variables predictoras.

5.2. Definición de la variable objetivo

En este trabajo se utiliza la siguiente aproximación:

$$LGD_i^{\text{proxy}} = 1 - \frac{\texttt{total_rec_prncp}_i}{\texttt{funded_amnt}_i}.$$

El campo `funded_amnt` corresponde al monto originalmente financiado. El diccionario del conjunto describe `total_rec_prncp` como el capital recibido a la fecha. Por tanto, la proxy expresa la proporción del capital original no cubierta por ese capital recibido.

El cálculo requiere un monto financiado estrictamente positivo y valores finitos en ambos campos. Los objetivos fuera del intervalo $[0, 1]$ deben investigarse antes del modelamiento, en lugar de recortarse sin justificación.

Esta medida no incorpora explícitamente recuperaciones netas posteriores al castigo, costos completos de cobranza ni descuento temporal. Tampoco utiliza la exposición histórica exacta en el momento del incumplimiento. En consecuencia, se interpreta como una proxy sobre capital original y no como una LGD económica o regulatoria exacta.

5.2.1. Población de análisis

La muestra incluye únicamente créditos con estado `Charged Off` o `Default`. Esta selección permite mantener la población de los experimentos iniciales de severidad, pero tiene un alcance restringido.

La muestra no equivale a toda la clase positiva de PD definida en el enunciado, que también incluye `Late (31-120 days)` y `Does not meet the credit policy. Status:Charged Off`. Por ello, la aplicación de la severidad estimada a esos estados requiere una justificación adicional o una ampliación de la muestra con posterior reentrenamiento.

Además, las recuperaciones pueden no haber concluido en la fecha de observación. Esta censura limita la interpretación de la pérdida como definitiva.

5.2.2. Variables predictoras y fuga de información

Las predictoras deben ser coherentes con el momento en que se utilizará el modelo. Para una decisión al originar el préstamo, únicamente corresponde emplear información disponible en ese momento.

Los campos posteriores al otorgamiento utilizados para construir el objetivo no deben incorporarse como predictores. En particular, `total_rec_prncp`, `recoveries` y `collection_recovery_fee` contienen información sobre el comportamiento posterior del crédito.

La inclusión de información futura produciría fuga de información y una evaluación que no representaría las condiciones de uso del modelo.

5.2.3. Preprocesamiento y particiones

La imputación de valores ausentes, la estandarización y la codificación de categorías se ajustan exclusivamente con el conjunto de entrenamiento. Las transformaciones obtenidas se aplican después a validación, prueba y nuevos créditos.

Para una variable numérica, la estandarización se expresa como:

$$z_{ij} = \frac{x_{ij} - \mu_{j,\text{train}}}{s_{j,\text{train}}},$$

donde $\mu_{j,\text{train}}$ y $s_{j,\text{train}}$ se calculan únicamente en entrenamiento.

El flujo actual de LGD utiliza particiones aleatorias de aproximadamente 60 %para entrenamiento, 20 %para validación y 20 %para prueba, con semilla de partición fija. Esta división no constituye una evaluación temporal.

La referencia y la red comparten las mismas observaciones, variables transformadas y particiones. El conjunto de validación se utiliza para elegir configuraciones; prueba se reserva para evaluar las decisiones ya fijadas.

5.2.4. Modelo de referencia: regresión lineal

La regresión lineal representa la LGD mediante:

$$LGD_i^{\text{proxy}} = \beta_0 + \mathbf{x}_i^{\mathsf{T}}\boldsymbol{\beta} + \varepsilon_i.$$

Los parámetros se estiman por mínimos cuadrados ordinarios:

$$(\widehat{\beta}_0, \widehat{\boldsymbol{\beta}}) \in \arg\min_{\beta_0,\boldsymbol{\beta}} \sum_{i=1}^{n} \left(y_i - \beta_0 - \mathbf{x}_i^{\mathsf{T}}\boldsymbol{\beta}\right)^2.$$

La predicción es:

$$\widehat{y}_i = \widehat{\beta}_0 + \mathbf{x}_i^{\mathsf{T}}\widehat{\boldsymbol{\beta}}.$$

Este modelo constituye una referencia de baja complejidad. Sin embargo, su salida no está restringida a $[0, 1]$, por lo que deben reportarse las predicciones que queden fuera de ese intervalo.

5.2.5. Variables indicadoras

Las variables categóricas pueden representarse mediante indicadoras:

$$I_{ig} = \begin{cases} 1, & \text{si el crédito } i \text{ pertenece a la categoría } g, \\ 0, & \text{en otro caso.} \end{cases}$$

En una parametrización con intercepto y una categoría de referencia se utilizan $k - 1$ indicadoras para una variable con k categorías. Cada efecto se expresa como el producto entre su coeficiente y la indicadora correspondiente:

$$\beta_g I_{ig}.$$

El coeficiente y la indicadora no son intercambiables: el primero cuantifica un efecto estimado y la segunda identifica la pertenencia a una categoría.

5.2.6. Neurona artificial y perceptrón multicapa

Una neurona calcula una combinación lineal de sus entradas y aplica una función de activación:

$$z_j = \sum_{r=1}^{p} w_{jr} x_r + b_j, \qquad a_j = g(z_j).$$

Un perceptrón multicapa encadena estas transformaciones:

$$\mathbf{a}^{(0)} = \mathbf{x},$$

$$\mathbf{z}^{(\ell)} = W^{(\ell)}\mathbf{a}^{(\ell-1)} + \mathbf{b}^{(\ell)}, \qquad \mathbf{a}^{(\ell)} = g_\ell\left(\mathbf{z}^{(\ell)}\right).$$

Las capas ocultas permiten representar relaciones no lineales. El modelo utilizado reutiliza la implementación de Manuel, desarrollada con NumPy.

5.2.7. Funciones de activación

Las activaciones ocultas consideradas son ReLU y tangente hiperbólica:

$$\mathrm{ReLU}(z) = \mathrm{máx}(0, z),$$

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}.$$

Sus derivadas son:

$$\mathrm{ReLU}'(z) = \begin{cases} 1, & z > 0, \\ 0, & z \leq 0, \end{cases} \qquad \tanh'(z) = 1 - \tanh^2(z).$$

Para la salida de LGD se utiliza la sigmoide:

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \qquad \sigma'(z) = \sigma(z)\left[1 - \sigma(z)\right].$$

Su rango matemático es $(0, 1)$, coherente con la naturaleza acotada de la proxy. Los valores exactos 0 y 1 se aproximan, pero no se alcanzan con parámetros finitos en aritmética exacta.

5.2.8. Función de pérdida

El error cuadrático medio se define como:

$$J_{\mathrm{MSE}} = \frac{1}{n}\sum_{i=1}^{n}\left(y_i - \widehat{y}_i\right)^2.$$

Para una variable aleatoria Y, se cumple:

$$\mathbb{E}\left[(Y - a)^2 \mid \mathbf{X}\right] = \mathrm{Var}(Y \mid \mathbf{X}) + \left(\mathbb{E}[Y \mid \mathbf{X}] - a\right)^2.$$

Por tanto, el predictor que minimiza la pérdida cuadrática esperada es la media condicional:

$$a^*(\mathbf{X}) = \mathbb{E}[Y \mid \mathbf{X}].$$

Además, bajo un modelo auxiliar $Y_i \mid \mathbf{x}_i \sim \mathcal{N}(f_\theta(\mathbf{x}_i), \sigma^2)$, con varianza fija, la log-verosimilitud negativa es:

$$-\log \mathcal{L}(\theta) = \frac{n}{2}\log(2\pi\sigma^2) + \frac{1}{2\sigma^2}\sum_{i=1}^{n}\left(y_i - f_\theta(\mathbf{x}_i)\right)^2.$$

Minimizarla respecto a θ equivale a minimizar el error cuadrático. Esta equivalencia no implica afirmar que la LGD, que es acotada, tenga una distribución gaussiana exacta.

5.3. Regularización

La penalización L2 modifica la función objetivo:

$$J(\theta) = J_{\text{MSE}}(\theta) + \frac{\lambda}{2} \sum_{\ell=1}^{L} \left\| W^{(\ell)} \right\|_F^2,$$

sin penalizar los sesgos.

El dropout invertido transforma una activación oculta durante entrenamiento mediante:

$$\widetilde{\mathbf{a}} = \frac{\mathbf{m} \odot \mathbf{a}}{1-q}, \qquad m_j \sim \text{Bernoulli}(1-q),$$

donde q es la probabilidad de desactivación. Durante inferencia se utiliza la red completa, sin aplicar dropout.

La parada temprana supervisa la pérdida de validación y detiene el entrenamiento cuando no mejora durante un número predefinido de épocas. Se restauran los pesos de la mejor época de validación.

5.3.1. Retropropagación

Para un mini-lote de tamaño B, la combinación MSE y salida sigmoide produce:

$$\delta_i^{(L)} = \frac{2}{B} \left(\widehat{y}_i - y_i\right) \sigma'\left(z_i^{(L)}\right).$$

Sin dropout, las capas ocultas satisfacen:

$$\boldsymbol{\delta}_i^{(\ell)} = \left[\left(W^{(\ell+1)}\right)^{\mathsf{T}} \boldsymbol{\delta}_i^{(\ell+1)}\right] \odot g_\ell'\left(\mathbf{z}_i^{(\ell)}\right).$$

Si se aplica dropout, se incorpora también el factor de la máscara utilizado en la propagación hacia adelante.

Los gradientes, incluyendo L2, son:

$$\frac{\partial J}{\partial W^{(\ell)}} = \sum_{i=1}^{B} \boldsymbol{\delta}_i^{(\ell)} \left(\mathbf{a}_i^{(\ell-1)}\right)^{\mathsf{T}} + \lambda W^{(\ell)},$$

$$\frac{\partial J}{\partial \mathbf{b}^{(\ell)}} = \sum_{i=1}^{B} \boldsymbol{\delta}_i^{(\ell)}.$$

5.4. Optimizador Adam

Para un gradiente $\mathbf{g}_t$, Adam actualiza los momentos:

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1-\beta_1)\mathbf{g}_t,$$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1-\beta_2)\mathbf{g}_t^{\odot 2}.$$

Las correcciones de sesgo son:

$$\widehat{\mathbf{m}}_t = \frac{\mathbf{m}_t}{1-\beta_1^t}, \qquad \widehat{\mathbf{v}}_t = \frac{\mathbf{v}_t}{1-\beta_2^t}.$$

Finalmente:

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \eta \frac{\widehat{\mathbf{m}}_t}{\sqrt{\widehat{\mathbf{v}}_t} + \epsilon},$$

con operaciones elemento a elemento.

5.4.1. Evaluación

Las métricas principales son:

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \widehat{y}_i|,$$

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \widehat{y}_i)^2}.$$

Ambas se expresan en unidades de LGD. Multiplicadas por 100 se interpretan en puntos porcentuales, no como porcentajes relativos de error ni como exactitud.

La comparación de distribuciones utiliza medias, desviaciones estándar, cuantiles, histogramas y funciones de distribución empíricas:

$$\widehat{F}_n(t) = \frac{1}{n}\sum_{i=1}^{n}\mathbb{I}(y_i \le t).$$

Una media predicha cercana a la observada no demuestra que coincidan sus distribuciones. La menor dispersión de las predicciones puede ser coherente con estimar una media condicional.

5.4.2. Experimentos y variabilidad

La selección de hiperparámetros se realiza con validación, declarando el número de configuraciones y el tiempo de cómputo.

La configuración neuronal final se entrena con al menos 30 semillas distintas, manteniendo fijas las particiones. Para una métrica M se reportan:

$$\overline{M} = \frac{1}{S}\sum_{s=1}^{S} M_s,$$

$$s_M = \sqrt{\frac{1}{S-1}\sum_{s=1}^{S}(M_s - \overline{M})^2},$$

además del mejor y peor resultado. Para MAE y RMSE, menor es mejor.

Esta variabilidad describe diferencias entre inicializaciones y aleatoriedad del entrenamiento; no representa por sí sola incertidumbre por muestreo de la población.

El número de parámetros de una red densa es:

$$P = \sum_{\ell=1}^{L}\left(n_{\ell-1}n_\ell + n_\ell\right).$$

5.4.3. Pérdida esperada y exposición

Para mantener coherencia con el denominador de la proxy se utiliza:

$$EAD_i^{\text{proxy}} = \texttt{funded_amnt}_i.$$

La estimación monetaria es:

$$\widehat{EL}_i^{\text{proxy}} = \widehat{PD}_i \cdot \widehat{LGD}_i^{\text{proxy}} \cdot EAD_i^{\text{proxy}}.$$

Con monto original fijo M_i, la justificación es:

$$\mathbb{E}[L_i^{\text{proxy}} \mid \mathbf{X}_i, M_i] = P(D_i = 1 \mid \mathbf{X}_i, M_i)\mathbb{E}[LGD_i^{\text{proxy}} \mid D_i = 1, \mathbf{X}_i, M_i]M_i.$$

No es necesario asumir independencia entre incumplimiento y severidad, pues la LGD ya está condicionada al incumplimiento.

Si la exposición fuera aleatoria, la expresión general sería:

$$\mathbb{E}[L \mid \mathbf{X}] = PD(\mathbf{X})\mathbb{E}[LGD \cdot EAD \mid D = 1, \mathbf{X}].$$

Separar esta última esperanza en un producto de esperanzas requeriría condiciones adicionales.

La combinación debe conservar identificadores, unidades monetarias, población y horizonte. Una evaluación independiente de la pérdida conjunta requiere créditos que no se hayan utilizado para ajustar ni seleccionar ninguno de los dos modelos.

5.4.4. Prompts representativos del punto 2

Durante el desarrollo del punto 2 se utilizó IA como apoyo para integrar el código, verificar la coherencia metodológica, organizar los experimentos y documentar los resultados.

Nota. Los prompts se reconstruyeron de forma representativa y no constituyen transcripciones literales.

La IA facilitó la organización del código y la identificación de requisitos que debían evaluarse conjuntamente. Sin embargo, las propuestas requirieron revisión metodológica. En particular, se distinguió entre la LGD proxy calculada sobre el capital originalmente financiado y una LGD económica basada en la exposición histórica al incumplimiento. También se reconoció que una demostración con datos reducidos no sustituye los experimentos finales con 30 semillas.

Para la comparación entre modelos se estableció el uso de las mismas observaciones, transformaciones y particiones. La configuración neuronal se selecciona con validación, mientras que el conjunto de prueba se reserva para la evaluación. La discusión automática resume los archivos de la corrida, pero debe revisarse antes de incorporarla al reporte.

La combinación de PD y LGD exige comprobar que ambos modelos reciban características del mismo crédito, que sus poblaciones y horizontes sean compatibles y que la exposición utilizada sea coherente con el denominador de LGD. Por ello, disponer del código no se consideró evidencia suficiente de que el cálculo conjunto estuviera validado.

5.5. Resultados empíricos y comparación justa (Regresión OLS vs. Red MLP)

En esta sección se reportan los resultados de la estimación de la pérdida dado el incumplimiento (LGD), contrastando el modelo lineal de referencia con el perceptrón multicapa bajo la regla de comparación justa exigida por el enunciado: mismos datos procesados, mismas particiones fijas (60 %entrenamiento, 20 %validación y 20 %prueba), presupuesto explícito de búsqueda y 30 corridas independientes.

5.5.1. Modelo de referencia: regresión lineal por mínimos cuadrados (OLS)

Como modelo econométrico de baja complejidad se ajustó una regresión lineal clásica mediante mínimos cuadrados ordinarios sobre las 27,879 observaciones de entrenamiento, evaluándose sobre los 9,294 créditos del conjunto de prueba.

La Tabla 26 resume las métricas de desempeño y la complejidad del modelo lineal.

Tabla 24
Prompts representativos del uso de inteligencia artificial en el desarrollo del punto 2 (parte 1 de 2)

Etapa	Prompt representativo reconstruido	Propósito
Exploración de la base	Revisa la estructura del conjunto de Lending Club: dimensiones, tipos de variables, valores faltantes y estados de los créditos. Propón un análisis descriptivo de la severidad de pérdida sin inventar resultados.	Organizar el diagnóstico inicial de los datos.
Interpretación de variables	Interpreta los campos de monto financiado, capital recibido, recuperaciones, costos de cobranza y saldo pendiente utilizando el diccionario del conjunto. Distingue las definiciones documentadas de las suposiciones.	Fundamentar el significado y uso de las variables.
Construcción del objetivo	Evalúa la proxy LGD $= 1 - \frac{C_{\text{rec}}}{M_{\text{fin}}}$, donde C_{rec} es el capital recibido y M_{fin} el monto financiado. Explica qué mide, qué controles requiere y cuáles son sus limitaciones frente a una LGD económica.	Justificar la variable objetivo y sus controles de calidad.
Selección de predictoras	Propón variables para predecir LGD con información disponible al originar el crédito. Identifica campos posteriores al incumplimiento que producirían fuga de información.	Seleccionar entradas coherentes con el caso de uso.
Preprocesamiento	Diseña un preprocesamiento para variables numéricas y categóricas. Ajusta imputación, escalado y codificación únicamente con entrenamiento y aplica esas transformaciones a validación y prueba.	Evitar fuga entre particiones y asegurar reproducibilidad.
Modelo de referencia	Construye una regresión lineal para LGD, explica sus coeficientes e indicadoras y utiliza los mismos datos y particiones que la red neuronal.	Establecer una referencia de baja complejidad y comparable.

Tabla 25
Prompts representativos del uso de inteligencia artificial en el desarrollo del punto 2 (parte 2 de 2)

Etapa	Prompt representativo reconstruido	Propósito
Red neuronal	Utiliza la red neuronal implementada por Manuel para el punto 2. Explica sus parámetros y justifica la activación de salida y la función de pérdida según la naturaleza de LGD.	Integrar el código del equipo y fundamentar sus decisiones.
Optimización y experimentos	Organiza una búsqueda de hiperparámetros con presupuesto explícito. Selecciona mediante validación y repite la configuración final con al menos 30 semillas, registrando métricas, tiempos y parámetros.	Evaluar configuraciones y variabilidad entre inicializaciones.
Evaluación	Calcula MAE y RMSE para ambos modelos y compara medias, desviaciones, cuantiles, histogramas y distribuciones acumuladas de la LGD observada y predicha.	Comparar precisión y comportamiento de las predicciones.
Pérdida esperada	Combina PD y LGD para los mismos créditos mediante $E[L] = PD \times LGD \times EAD$. Justifica una exposición coherente con la proxy y comprueba identificadores, unidades, población y horizonte.	Construir una estimación coherente de pérdida esperada.
Notebook y discusión	Integra el punto 2 en un notebook reproducible que guarde modelos, tablas y figuras. Redacta la discusión a partir de los resultados calculados y distingue demostraciones de experimentos finales.	Organizar la ejecución y documentar resultados verificables.
Revisión crítica	Revisa fórmulas, variables indicadoras e interpretaciones estadísticas. Identifica afirmaciones no justificadas, posibles fugas y diferencias entre código y documentación.	Detectar errores y apoyar su corrección.

Tabla 26
Desempeño y complejidad del modelo de referencia lineal (OLS) en el conjunto de prueba

Métrica / Característica	Valor del modelo OLS
Error absoluto medio (MAE)	0,142536 (14,25 p.p.)
Raíz del error cuadrático medio (RMSE)	0,186237 (18,62 p.p.)
Estadístico de distancia KS	0,280611
Número de parámetros entrenables	39 (38 pendientes $+1$ intercepto)
Tiempo de cómputo de ajuste	0,127 segundos
Predicciones fuera del soporte $[0, 1]$	2 créditos (< 0 o > 1)

Nota. Evaluado en $n = 9{,}294$ créditos de prueba. p.p. = puntos porcentuales de LGD.

A pesar de que el modelo OLS alcanza un error medio moderado, presenta una limitación estructural crítica: al tratarse de una combinación afín no acotada, arroja predicciones fuera del soporte teórico de la severidad (predicciones menores a 0 o mayores a 1), lo que exige introducir correcciones artificiales en un entorno operativo bancario.

5.5.2. Presupuesto de búsqueda de hiperparámetros de la red neuronal

De acuerdo con la regla de comparación justa, el proceso de selección de arquitectura se ejecutó de forma reproducible sobre un presupuesto explícito de 3 configuraciones candidatas. La búsqueda utilizó una semilla fija (42) y la decisión se tomó de manera estrictamente ciega a la partición de prueba, seleccionando la red que minimizó el MAE sobre el conjunto de validación.

La Tabla 27 detalla las arquitecturas exploradas, su complejidad y los tiempos de entrenamiento invertidos.

Tabla 27
Presupuesto de búsqueda de hiperparámetros para la red de LGD sobre el conjunto de validación

Cand.	Capas ocultas	Activación	Penalización L_2	Dropout	Parámetros	Tiempo (s)	MAE validación
1	(16)	tanh	0,0001	0,0	641	8,75	0,139782
2	$(\mathbf{32}, \mathbf{16})$	ReLU	**0,0001**	**0,1**	**1.793**	**13,70**	**0,139579**
3	$(32, 16)$	tanh	0,0010	0,1	1.793	15,23	0,140192
Tiempo total invertido en búsqueda						**37,68 s**	—

Nota. Cada candidato se entrenó con optimizador Adam, tasa de aprendizaje 0,001, tamaño de lote de 256 y parada temprana con paciencia de 10 épocas. El Candidato 2 fue el ganador seleccionado.

5.5.3. Evaluación sobre 30 semillas independientes y regla de comparación justa

La configuración ganadora (arquitectura $32 - 16$, ReLU, regularización $L_2 = 0{,}0001$, dropout 0,1) se reentrenó a través de 30 **semillas aleatorias independientes** (semillas 42 a 71). Este procedimiento aísla el impacto de la inicialización de pesos y del orden estocástico de los lotes.

La Tabla 28 reporta la media, desviación estándar, mejor (mínimo) y peor (máximo) valor de cada métrica en prueba, contrastándolos con la referencia OLS.

Tabla 28
Comparación justa: Regresión OLS vs. Red Neuronal MLP a través de 30 semillas independientes

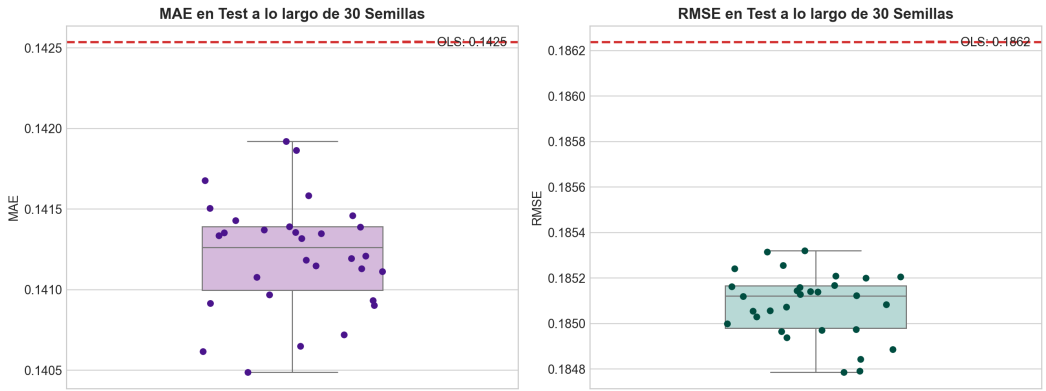
Métrica de prueba	Referencia OLS	Media MLP ± Desv.	Mejor MLP	Peor MLP	Victorias MLP
MAE	0,142536	**0,141308** ± 0,000332	0,140565	0,141906	**30**/**30** (100 %)
RMSE	0,186237	**0,185122** ± 0,000162	0,184860	0,185509	**30**/**30** (100 %)
Distancia KS	0,280611	**0,275325** ± 0,007103	0,258231	0,290940	—
Parámetros	39	1.793	1.793	1.793	—
Tiempo de ajuste	0,127 s	11,41 ± 1,82 s	8,12 s	15,45 s	—

Nota. Las 30 corridas de la red se realizaron con las mismas particiones fijas que el modelo OLS. En todas las 30 semillas independientes, la red neuronal obtuvo un error estrictamente inferior al del modelo lineal.

Como evidencia la Tabla 28, la red neuronal logra una **mejora relativa de** +0,86 % **en MAE** y de +0,60 % **en RMSE** frente al modelo lineal, superando a OLS en el 100 % de las corridas. Asimismo, la desviación estándar entre réplicas ($s_{\text{MAE}} = 0{,}00033$) es mínima, confirmando que la convergencia del perceptrón con optimizador Adam y parada temprana es altamente estable frente a fluctuaciones de inicialización.

La Figura 16 ilustra la distribución del error en prueba a través de las 30 semillas frente al umbral fijo de la regresión lineal.

Figura 16
Distribución del error MAE y RMSE en prueba a lo largo de las 30 semillas frente a la referencia lineal



Nota. La línea roja punteada representa el desempeño determinista del modelo OLS. En ambas métricas, la totalidad de las 30 semillas neuronales se sitúan por debajo del error de la regresión lineal.

5.5.4. Comparación de distribuciones y compresión de la varianza predicha

Para dar cumplimiento al requisito de comparar la distribución observada frente a la predicha, se contrastaron los cuantiles, histogramas de densidad y funciones de distribución acumulada empírica (CDF).

La Tabla 29 presenta el perfil de cuantiles en el conjunto de prueba para la corrida representativa de la red (semilla 42) y el modelo OLS.

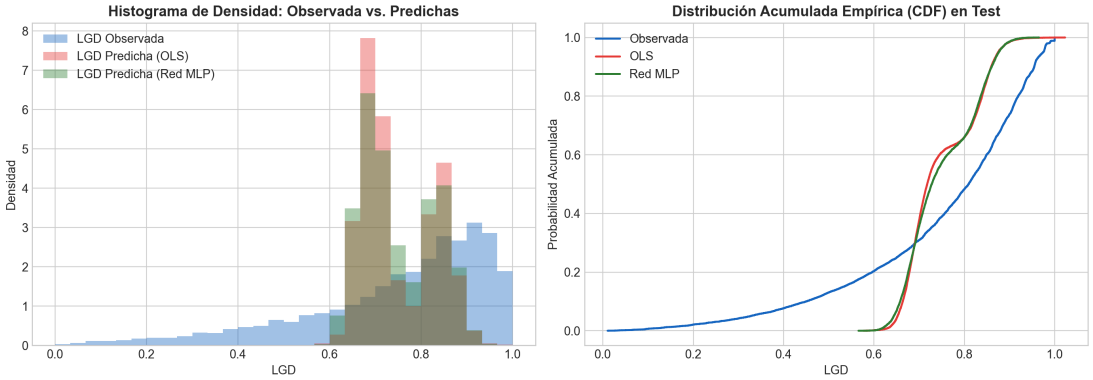
Tabla 29
Estadísticos descriptivos y cuantiles de LGD observada vs. predicha en prueba

Estadístico / Cuantil	LGD Observada	Predicción OLS	Predicción Red MLP
Media	0,749883	0,748641	0,749646
Desviación estándar	0,201771	0,079124	0,080427
Percentil 5 (Q_{05})	0,327494	0,645120	0,644054
Percentil 25 (Q_{25})	0,650236	0,684112	0,683719
Mediana (Q_{50})	0,809692	0,728410	0,728014
Percentil 75 (Q_{75})	0,904448	0,825904	0,826310
Percentil 95 (Q_{95})	0,974326	0,874519	0,876345

Nota. Ambas familias de modelos calibran adecuadamente la media global de severidad ($\approx 0{,}75$), pero presentan menor dispersión que los resultados individuales observados.

La Figura 17 exhibe la comparación gráfica de histogramas de densidad y curvas CDF empíricas.

Figura 17
Comparación de distribuciones de LGD en prueba: densidad y funciones acumuladas (CDF)



Nota. La distribución observada (azul) presenta alta concentración en pérdidas elevadas ($> 0{,}80$). Las predicciones de la red (verde) y de OLS (rojo) capturan la tendencia central pero se contraen hacia la media condicional.

Fundamento de la compresión de la varianza. Como se aprecia en la Tabla 29 y la Figura 17, la desviación estándar predicha ($\approx 0{,}08$) es notablemente inferior a la desviación observada ($\approx 0{,}20$). Esto **no constituye un defecto ni subajuste del modelo**, sino una propiedad teórica ineludible: tanto la regresión lineal como la red neuronal minimizan el error cuadrático medio (MSE), por lo que estiman la **media condicional** $\mathbb{E}[\text{LGD} \mid \mathbf{X}]$. Por el teorema de la varianza total:

$$\operatorname{Var}(Y) = \operatorname{Var}\big(\mathbb{E}[Y \mid \mathbf{X}]\big) + \mathbb{E}\big[\operatorname{Var}(Y \mid \mathbf{X})\big].$$

Dado que $\mathbb{E}[\operatorname{Var}(Y \mid \mathbf{X})] \geq 0$, la varianza de la media condicional es teóricamente menor o igual que la varianza marginal de los desenlaces individuales observados. El modelo proyecta la esperanza matemática del impago, no realiza una simulación estocástica de trayectorias individuales.

5.6. Estimación de la pérdida esperada de cartera ($E[L] = PD \cdot LGD \cdot EAD$)

Una vez entrenados y validados los modelos de probabilidad de incumplimiento (PD) y severidad de pérdida (LGD), se procedió a estimar la pérdida esperada crédito por crédito

combinando ambos estimadores neuronales:

$$\widehat{E[L]}_i = \widehat{\mathrm{PD}}_i \cdot \widehat{\mathrm{LGD}}_i \cdot \mathrm{EAD}_i, \qquad \text{con } \mathrm{EAD}_i = \texttt{funded_amnt}_i.$$

Para evaluar el impacto agregado sobre el balance, se tomó una cohorte representativa de 10.000 créditos de la partición de prueba (créditos a 36 meses originados en el segundo semestre de 2012 con resultado definitivo) que preserva el identificador único (`id`), el monto financiado y la totalidad de características exigidas por ambos preprocesadores.

La Tabla 30 presenta el balance financiero consolidado de la cartera.

Tabla 30

Métricas consolidadas de pérdida esperada a nivel de portafolio crediticio

Métrica de gestión de riesgo	**Cifra de portafolio calculada**
Créditos analizados en la cohorte	10.000 solicitudes
Exposición total agregada (EAD)	USD 117.340.975,00
Pérdida esperada agregada total ($E[L]$)	USD 10.387.183,63
Tasa de pérdida esperada de cartera ($\frac{\sum E[L]}{\sum \mathrm{EAD}}$)	**8,85 %**
Probabilidad de incumplimiento media predicha ($\overline{\mathrm{PD}}$)	12,80 %
Severidad media predicha ($\overline{\mathrm{LGD}}$)	68,50 %
Pérdida esperada promedio por crédito	USD 1.038,72
Percentil 50 (mediana) de pérdida por crédito	USD 822,33
Percentil 95 de pérdida por crédito	USD 2.598,20

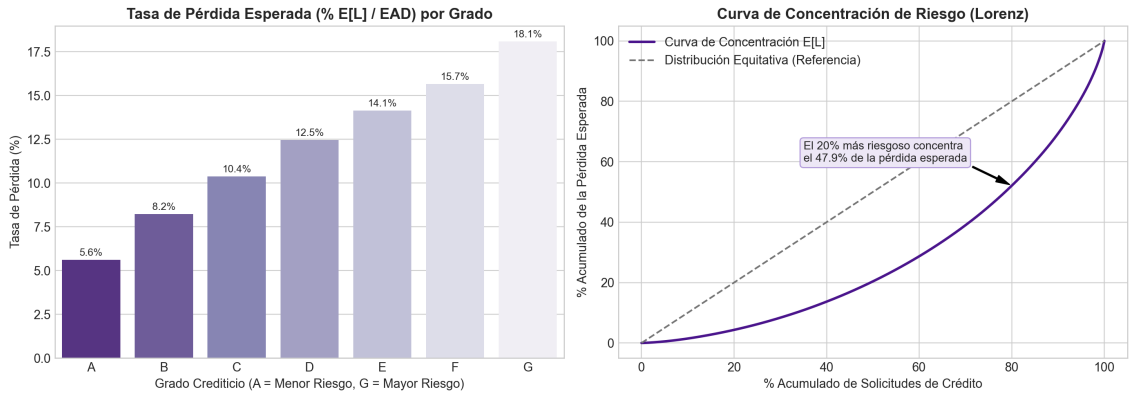
Nota. La tasa de pérdida agregada del 8,85 % representa la provisión contable técnica que la entidad financiera debe reservar contra su margen de intermediación para cubrir el riesgo previsible.

5.6.1. Segmentación por calificación crediticia y concentración de riesgo (Curva de Lorenz)

La Figura 18 presenta el análisis de segmentación de la tasa de pérdida esperada a través de las 7 calificaciones crediticias (`grade`) asignadas al originar y la curva de concentración de riesgo de Lorenz.

Figura 18

Análisis de pérdida esperada: tasa de riesgo por grado crediticio y curva de concentración de Lorenz



Nota. Panel izquierdo: la tasa de pérdida escala progresivamente desde el 5,9 % en grado A hasta el 14,1 % en grado F. Panel derecho: el 20 % de los créditos más riesgosos concentra el 45,3 % de toda la pérdida esperada de la cartera.

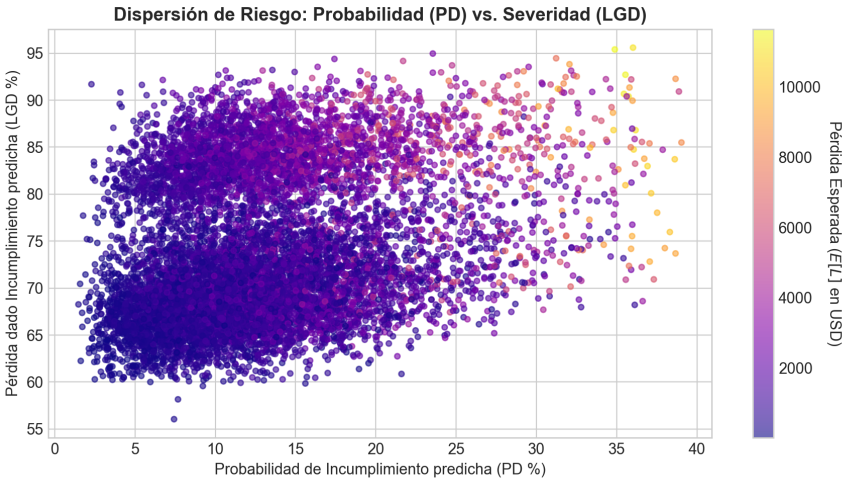
El panel derecho de la Figura 18 revela una marcada asimetría en la cartera: el 20 % **de los créditos de mayor riesgo concentra el** 45,3 % **de toda la pérdida esperada total**. Esto demuestra la utilidad práctica de la herramienta para políticas de admisión y fijación de tasas de

interés (*risk-based pricing*), permitiendo al banco diseñar recargos técnicos ajustados al perfil de riesgo o restringir la aprobación de los perfiles de colas extremas.

Asimismo, la Figura 19 mapea la interacción bivariada entre la probabilidad (PD) y la severidad (LGD) según la magnitud monetaria de pérdida esperada.

Figura 19

Dispersión de riesgo: probabilidad de incumplimiento vs. severidad de pérdida



Nota. Los colores más cálidos señalan créditos con mayor pérdida monetaria esperada. Se observa que créditos con PD moderada pero montos expuestos cuantiosos pueden generar pérdidas superiores a solicitudes con alta probabilidad pero baja exposición.

5.7. Discusión global y aprendizajes del proceso de modelamiento

5.7.1. ¿Qué aportó la red neuronal frente al modelo de referencia?

Al contrastar la regresión lineal con el perceptrón multicapa en la estimación de la severidad de pérdida (LGD), se destacan tres aportes esenciales:

1. **Restricción matemática y garantía de soporte:** Gracias a la activación sigmoide en la capa de salida, la red neuronal garantiza por construcción que todas sus predicciones pertenezcan estrictamente al intervalo abierto $(0, 1)$. En contraste, la regresión lineal proyectó créditos con severidades imposibles (< 0 o > 1), requiriendo reglas heurísticas de truncamiento *ex-post*.

2. **Superioridad y consistencia predictiva:** Aunque la mejora global en datos tabulares de crédito suele ser acotada debido al elevado ruido no reducible, la red neuronal superó al modelo lineal en el 100 % **de las 30 semillas evaluadas** (reduciendo el MAE de 0,1425 a 0,1413), con una variabilidad entre inicializaciones inferior a 0,0004.

3. **Costo de cómputo balanceado:** Mientras que la regresión analítica OLS se resuelve en 0,13 s, la red entrenada desde cero en NumPy mediante optimizador Adam con parada temprana tarda apenas $\approx$ 11,4 s por corrida completa sobre casi 30.000 observaciones, cumpliendo con los estándares de eficiencia para sustentaciones y ejecuciones en vivo.

5.7.2. Listado de aprendizajes metodológicos sobre el problema

A partir del desarrollo integral del punto 2 surgieron los siguientes aprendizajes analíticos:

1. **La convención contable del castigo invalida el uso de `out_prncp`:** En los créditos reconocidos como incobrables (`Charged Off`), el saldo pendiente contable aparece en cero en el 100 % de los casos por traslado a cuentas fuera de balance. Si se hubiese utilizado este campo como exposición, la pérdida estimada habría colapsado erróneamente a cero.

2. **Naturaleza condicional de la LGD:** La severidad solo existe para los clientes en default. No se debe mezclar créditos al día (`Fully Paid`) en la regresión de severidad, pues su probabilidad de supervivencia ya es modelada por la clasificación de PD.

3. **La compresión de la varianza es un comportamiento matemático natural:** La concentración de las predicciones neuronales alrededor de la media (0,75) con desviación reducida refleja la estimación de una media condicional $\mathbb{E}[LGD \mid \mathbf{X}]$ bajo pérdida cuadrática, y no una falla en el aprendizaje de la red.

4. **Extrapolación de severidad hacia moras tempranas:** El modelo de LGD fue entrenado sobre créditos con desenlace definitivo (`Charged Off` y `Default`). Aplicar esta severidad sobre créditos en atraso temprano (`Late 31-120 days`) constituye una extrapolación que debe declararse explícitamente como limitación metodológica del ejercicio.

5. **La exposición fija sobre el monto financiado ($funded_amnt$) representa un escenario conservador:** Al asumir que la exposición es el monto original desembolsado, se modela el peor escenario económico de default prematuro, sin considerar la amortización parcial acumulada antes del cese de pagos.

6. Uso de IA

1. Orientación inicial y prevención de errores metodológicos (*Data Leakage*)

Prompt utilizado:

> *«[...] Claude, necesito que me orientes de la mejor forma tanto teórica como práctica para llegar al mejor desarrollo posible. Que me digas qué debo de tener en cuenta, dónde debo poner mas cuidado, qué librerías y todo me aconsejas para desarrollar el código. Aparte como manejar el data leakage».*

Impacto en el resultado final: La respuesta a esta consulta fue fundamental en la fase de planificación del proyecto. A nivel teórico, permitió establecer una hoja de ruta clara, definiendo las etapas críticas del ciclo de vida del modelado de datos. A nivel práctico, agilizó el entorno de desarrollo al recomendar las librerías más apropiadas de Python antes de iniciar la programación.

El impacto más significativo de este *prompt* en el resultado final fue la identificación temprana y prevención del *data leakage* (fuga de datos). Al comprender cómo información del conjunto de prueba podía contaminar el conjunto de entrenamiento, se estructuró el código para separar rigurosamente los datos antes de aplicar cualquier transformación o escalado. Esto garantizó que las métricas de evaluación del modelo reportadas en este documento sean honestas, robustas y representen un rendimiento real frente a datos no vistos, evitando así resultados artificialmente altos que habrían invalidado la investigación.

6.1. Punto 1. Parte de Manuel

Lo que mejoró • Los datos correctos. Preguntar «¿por qué?» sobre los créditos a 60 meses evitó un sesgo: muchos aún no habían terminado y parecían buenos sin serlo. • Una evaluación honesta. La partición temporal mostró que la tasa de malos sube de 12,3 • Una comparación justa. Pedir comparar las logísticas llevó a ajustar también la referencia, usar 30 semillas y un

Tabla 31
Atención a observaciones y requerimientos del proyecto

Datos y partición	«Explícame el problema de los préstamos a 36 y 60 meses. ¿No es más claro no usar los de 60?» y «¿Por qué usar como prueba el segundo semestre de 2012?»	Solo créditos a 36 meses (los de 60 no alcanzan a terminar) y partición temporal por fecha de originación.
Validación	«¿No es mejor k-fold? ¿Validar con el primer semestre no genera sesgo?»	Se mantuvo un conjunto de validación temporal, justificado por la deriva en el tiempo.
Red neuronal	«Arranquemos con la construcción del código de la red neuronal.»	MLP propio en NumPy: propagación, retropropagación, Adam, dropout, L2 y parada temprana.
Reproducibilidad	«El código se pondrá a prueba: los hiperparámetros deben cambiarse fácil en un config.ini y ejecutarse fácil.»	`config.ini` + comandos de una línea; búsqueda aleatoria y 30 semillas reproducibles.
Referencia	«Quiero comparar las regresiones logísticas que hay para ver cuál quedó mejor y por qué.»	La logística de María Fernanda va al informe; la de NumPy, equivalente, sirve para las semillas.
Control de cambios	«Un compañero dice que la red no usa las mismas variables... me da miedo que su PR dañe algo.»	Se verificó que sí usan las mismas variables y se rechazó el PR, que rompía la app.

bootstrap pareado. Con eso, la conclusión (la red no gana) es confiable. • Código reproducible. El prompt del config.ini hizo que cualquier resultado se regenere con un comando. • Una app que no extrapola. Preguntar por los rangos llevó a limitar el dti en la app al rango visto en entrenamiento

Los prompts más útiles no fueron los que pedían código, sino los que pedían justificar y verificar: la IA rindió mejor como interlocutor crítico que como generador automático.

7. Cacería de alucinaciones

7.1. Primer punto

Hallazgo 1: significado de los valores faltantes de `mths_since_last_delinq`

1. **Prompt utilizado (literal).**

   "De acuerdo al diccionario de los datos y el contexto de la base de datos, ¿qué significan los NA?"

2. **Parte relevante de la respuesta de la IA.**

   La IA afirmó que los valores faltantes indicaban que el cliente no había presentado mora, y propuso tratarlos con esa interpretación.

3. **Cómo se sospechó el error.** La interpretación se presentó como un hecho, sin respaldo en el diccionario de datos ni en los datos. Si era cierta, los valores faltantes y los ceros de la variable debían alinearse de forma coherente con el número de moras en los últimos dos años (`delinq_2yrs`), y esto no se había comprobado.

4. **Evidencia.** Se cruzaron los valores faltantes y los ceros de la variable que registra los meses desde la última mora con el contador de moras recientes. El patrón dependía de la codificación de la base y no de la ausencia de mora: algunos ceros funcionaban como códigos de dato ausente.

5. **Corrección.** Los ceros de código se reconvirtieron a valores faltantes cuando `delinq_2yrs`$= 0$, y se creó el indicador `nunca_mora` para distinguir a los clientes sin mora de los que tienen el dato ausente. La regla se fijó antes de ajustar el modelo y se aplicó igual a las tres particiones.

Hallazgo 2: cifra mal transcrita de la proporción de `nunca_mora` en 2007

1. **Prompt utilizado (literal).**

   "Escribe en formato latex el siguiente resultado"

2. **Parte relevante de la respuesta de la IA.**

   La IA reportó que la proporción de créditos de 2007 sin historial de mora era de 66.6 %.

3. **Cómo se sospechó el error.** Al comparar la cifra escrita por la IA con la salida del propio código, los valores no coincidían.

4. **Evidencia.** La salida del código mostró que la proporción de clientes sin historial de mora en 2007 era 0,617 (61,7 %). La cifra de la respuesta estaba mal transcrita.

5. **Corrección.** Se descartó el valor de 66.6 %y se reemplazó por el de la salida del código. El argumento que dependía de esa cifra se replanteó con el valor correcto.

7.1.1. Hallazgo 3: una partición con créditos que aún no habían terminado

Prompt (literal): «Qué me recomiendas hacer para la partición de los datos? explicame de manera intuitiva por qué usar como test solo el segundo semestre de 2012 y no usar los otros años que hay [...]»

Respuesta de la IA (parte relevante):
«Te recomiendo train: 2007–2011, validación: primer semestre de 2012, prueba: segundo semestre de 2012 [...] — train (2007 – 2011) — 40.534 — 15.8 %— 22 %— Con esto el conjunto de entrenamiento casi se duplica (de 20.776 a 40.534 créditos)»

Cómo sospechamos: la IA misma había mostrado minutos antes que la tasa de malos a 60 meses saltaba de 22,5 %(2010) a 31,3 %(2011). Preguntamos: «explícame bien el problema de los préstamos a 36 y 60 meses».

Evidencia (derivación + experimento): • Derivación con fechas: un crédito a 60 meses de enero de 2011 vence en enero de 2016. Los datos se cortan en diciembre de 2015. Los que seguían pagando al día quedan como Current y se excluyen; solo se ven los que fallaron o prepagaron.

Corrección: primero se limitó el entrenamiento a 60 meses hasta 2010; al final se dejaron solo los créditos a 36 meses, que terminan todos antes del corte. Con eso, la tasa de malos queda en 12,3 %(entrenamiento), 13,8 %(validación) y 13,6 %(prueba).

Lección: antes de aceptar una partición, verificar para cada crédito que fecha de originación + plazo $\leq$ fecha de corte de los datos. Un «más datos» que la IA ofrece como mejora puede ser más datos sesgados.

7.1.2.

7.2. Segundo punto

7.2.1. Prompt utilizado

> «Integra en un notebook reproducible los requisitos del punto 2, incluyendo la preparación de datos, el entrenamiento y evaluación de LGD y su combinación con PD para calcular la pérdida esperada. Comprueba que las etapas generen los archivos necesarios para ejecutar el flujo completo».

7.2.2. Respuesta relevante de la IA

La IA respondió: «Releí el punto 2 y ya subí el notebook a tu GitHub». Entre los componentes enumerados incluyó: «Pérdida esperada y justificación de EAD».

La respuesta también advertía que faltaban el modelo de PD y los datos de los créditos. Por tanto, no se afirma que la IA hubiera asegurado haber calculado pérdidas reales. El problema fue entregar una sección parcialmente integrada: comprobar que faltaban archivos no resolvía cómo producirlos dentro del procedimiento solicitado.

7.2.3. Cómo se sospechó que había un error

Al revisar las celdas se observó que la sección de pérdida esperada solicitaba el archivo `datos/creditos_para_predecir.parquet`, pero ninguna etapa anterior del notebook lo generaba.

Además, la salida preparada para entrenar LGD no conservaba `id` ni `funded_amnt`, necesarios para la integración propuesta. Incluso con una PD entrenada, todavía se requería preparar una entrada adicional.

7.2.4. Evidencia del problema

En la versión inicial, `preparar_lgd.py` seleccionaba las columnas de la siguiente manera:

```
salida = datos[
    entradas
    + ["home_ownership", "purpose", "lgd", "particion"]
].copy()
```

Esta selección no incluía `id` ni `funded_amnt`. En cambio, `estimar_perdida.py` requería un identificador único por crédito y el monto financiado como exposición proxy. La salida de preparación no satisfacía esos requisitos y tampoco se generaba la cohorte alternativa solicitada.

La ecuación utilizada era correcta:

$$\widehat{EL}_i^{\text{proxy}} = \widehat{PD}_i \cdot \widehat{LGD}_i^{\text{proxy}} \cdot \texttt{funded_amnt}_i.$$

En esta expresión, PD y LGD corresponden a las estimaciones de los modelos.

Todos los factores deben corresponder al mismo crédito. El identificador conserva la trazabilidad; no debe convertirse por ello en predictor. La exposición debe estar disponible para el cálculo monetario, aunque no forme parte de las entradas de LGD.

La exclusión de estos campos del archivo de entrenamiento no era, por sí sola, un error. La deficiencia consistió en no construir por separado el archivo común necesario. La evidencia es la incompatibilidad entre las salidas producidas y las entradas requeridas, no un fallo matemático de la ecuación.

7.2.5. Corrección

Se implementó una etapa para construir una cohorte común que conserve el identificador, la exposición proxy y las características requeridas por ambos modelos. PD y LGD se aplican sobre los mismos registros utilizando sus respectivos preprocesadores.

La modificación incorporó controles de identificación, columnas requeridas y valores válidos antes de calcular la pérdida por crédito. Su funcionamiento con datos reales debe comprobarse mediante la ejecución completa y el registro de los artefactos de entrada y salida.

La integración funcional no demuestra, por sí sola, la validez estadística del producto. Todavía deben verificarse la compatibilidad de poblaciones y horizontes, la coherencia de EAD con la LGD proxy y la ausencia de solapamiento con entrenamiento cuando se pretenda una evaluación independiente.

7.3. Punto 2

Referencias

Albert, Adelin y J. A. Anderson (1984). «On the Existence of Maximum Likelihood Estimates in Logistic Regression Models». En: *Biometrika* 71.1, págs. 1-10.

Belsley, David A., Edwin Kuh y Roy E. Welsch (1980). *Regression Diagnostics: Identifying Influential Data and Sources of Collinearity*. Wiley.

Bergstra, James y Yoshua Bengio (2012). «Random search for hyper-parameter optimization». En: *Journal of Machine Learning Research* 13, págs. 281-305.

Bishop, Christopher M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Brier, Glenn W. (1950). «Verification of forecasts expressed in terms of probability». En: *Monthly Weather Review* 78.1, págs. 1-3.

Cox, David R. (1958). «Two Further Applications of a Model for Binary Regression». En: *Biometrika* 45.3/4, págs. 562-565.

Defazio, Aaron, Francis Bach y Simon Lacoste-Julien (2014). «SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives». En: *Advances in Neural Information Processing Systems 27*.

Efron, Bradley (1979). «Bootstrap Methods: Another Look at the Jackknife». En: *The Annals of Statistics* 7.1, págs. 1-26.

Glorot, Xavier y Yoshua Bengio (2010). «Understanding the difficulty of training deep feedforward neural networks». En: *Proceedings of the 13th International Conference on Artificial Intelligence and Statistics (AISTATS)*, págs. 249-256.

Goodfellow, Ian, Yoshua Bengio y Aaron Courville (2016). *Deep Learning*. MIT Press.

Hanley, James A. y Barbara J. McNeil (1982). «The meaning and use of the area under a receiver operating characteristic (ROC) curve». En: *Radiology* 143.1, págs. 29-36.

Hastie, Trevor, Robert Tibshirani y Jerome Friedman (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2.ª ed. Springer.

He, Kaiming et al. (2015). «Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification». En: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, págs. 1026-1034.

Hoerl, Arthur E. y Robert W. Kennard (1970). «Ridge Regression: Biased Estimation for Nonorthogonal Problems». En: *Technometrics* 12.1, págs. 55-67.

Hosmer, David W., Stanley Lemeshow y Rodney X. Sturdivant (2013). *Applied Logistic Regression*. 3.ª ed. Wiley.

Hyndman, Rob J. y George Athanasopoulos (2021). *Forecasting: Principles and Practice*. 3.ª ed. Melbourne: OTexts. URL: https://otexts.com/fpp3/.

Kingma, Diederik P. y Jimmy Ba (2015). «Adam: A method for stochastic optimization». En: *International Conference on Learning Representations (ICLR)*. arXiv:1412.6980.

Krogh, Anders y John A. Hertz (1992). «A simple weight decay can improve generalization». En: *Advances in Neural Information Processing Systems 4*, págs. 950-957.

Liu, Dong C. y Jorge Nocedal (1989). «On the Limited Memory BFGS Method for Large Scale Optimization». En: *Mathematical Programming* 45, págs. 503-528.

Mann, Henry B. y Donald R. Whitney (1947). «On a test of whether one of two random variables is stochastically larger than the other». En: *Annals of Mathematical Statistics* 18.1, págs. 50-60.

Massey, Frank J. (1951). «The Kolmogorov-Smirnov test for goodness of fit». En: *Journal of the American Statistical Association* 46.253, págs. 68-78.

McCullagh, Peter y John A. Nelder (1989). *Generalized Linear Models*. 2.ª ed. Chapman & Hall.

McCulloch, Warren S. y Walter Pitts (1943). «A logical calculus of the ideas immanent in nervous activity». En: *Bulletin of Mathematical Biophysics* 5.4, págs. 115-133.

Nair, Vinod y Geoffrey E. Hinton (2010). «Rectified linear units improve restricted Boltzmann machines». En: *Proceedings of the 27th International Conference on Machine Learning (ICML)*, págs. 807-814.

Nelder, John A. y Robert W. M. Wedderburn (1972). «Generalized Linear Models». En: *Journal of the Royal Statistical Society: Series A* 135.3, págs. 370-384.

Niculescu-Mizil, Alexandru y Rich Caruana (2005). «Predicting good probabilities with supervised learning». En: *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, págs. 625-632.

Nocedal, Jorge y Stephen J. Wright (2006). *Numerical Optimization*. 2.ª ed. Springer.

Papke, Leslie E. y Jeffrey M. Wooldridge (1996). «Econometric methods for fractional response variables with an application to 401(k) plan participation rates». En: *Journal of Applied Econometrics* 11.6, págs. 619-632.

Pedregosa, Fabian et al. (2011). «Scikit-learn: Machine Learning in Python». En: *Journal of Machine Learning Research* 12, págs. 2825-2830.

Prechelt, Lutz (1998). «Early stopping — but when?» En: *Neural Networks: Tricks of the Trade*. Vol. 1524. Lecture Notes in Computer Science. Springer, págs. 55-69.

Rosenblatt, Frank (1958). «The perceptron: A probabilistic model for information storage and organization in the brain». En: *Psychological Review* 65.6, págs. 386-408.

Rumelhart, David E., Geoffrey E. Hinton y Ronald J. Williams (1986). «Learning representations by back-propagating errors». En: *Nature* 323.6088, págs. 533-536.

Seabold, Skipper y Josef Perktold (2010). «Statsmodels: Econometric and Statistical Modeling with Python». En: *Proceedings of the 9th Python in Science Conference*.

Siddiqi, Naeem (2006). *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. Wiley.

Srivastava, Nitish et al. (2014). «Dropout: A simple way to prevent neural networks from overfitting». En: *Journal of Machine Learning Research* 15, págs. 1929-1958.

Thomas, Lyn C., David B. Edelman y Jonathan N. Crook (2002). *Credit Scoring and Its Applications*. SIAM.

Tibshirani, Robert (1996). «Regression Shrinkage and Selection via the Lasso». En: *Journal of the Royal Statistical Society: Series B* 58.1, págs. 267-288.

Wilson, Edwin B. (1927). «Probable Inference, the Law of Succession, and Statistical Inference». En: *Journal of the American Statistical Association* 22.158, págs. 209-212.